## 目标成绩: \_\_A\_\_\_

## 大数据实验报告 (实验 2)

班级 21 计算机 4 班 学号 2021329600006 姓名 陈昊天

实验时间: \_2024.04.09\_

## 一、实验名称:

HDFS 基本操作及 API 编程

## 二、实验目的

要求学生

- 1、具备使用 Hadoop 命令来操作分布式文件系统的能力。
- 2、利用 HDFS 文件系统开放的 API 对 HDFS 系统进行文件的创建和读写。 为此完成以下二个模块的工作:

#### 模块一 HDFS 的 Shell 客户端操作

- 1 完成 HDFS 环境搭建
- 2 通过 HDFS 的 Shell 客户端,掌握对 HDFS 所提供的文件接口的操作能力。
- 3 设计一个实验方案,以验证 HDFS 的组成架构和文件块大小等核心概念。

#### 模块二 HDFS 的 Java 客户端 API 编程

- 1、HDFS的 JAVA 客户端环境准备。
- 2、通过 HDFS 的 JAVA 客户端,掌握对 HDFS 的编程接口 API 对文件的操作能力

- 3、设计一个实验方案,通过 HDFS 的 API 操作,实现文件上传、文件下载、文件夹删除、文件名更改、文件和文件夹判断,以及用 I/O 流操作 HDFS。
- 4、通过对 HDFS 写数据流的流程知识,详细分析自己实验方案中"文件写入"的过程。

## 三、实验设计

(在此, 描述你根据实验目的和老师给的参考, 分别对模块一和模块二设定的实验步骤)

## 模块一 HDFS 的 Shell 客户端操作

## 1 完成 HDFS 环境搭建

以 Debian 12 为例

#### (1) 安装 JDK8

使用 adoptium 源安装 temurin-8-jdk

#### (2) 设置环境变量

包括 JAVA\_HOME、HADOOP\_HOME 和 PATH

#### (3) 下载 Hadoop

下载并解压 hadoop-3.3.6

#### (4) 配置 SSH 免密登录

使用 ssh-keygen 生成密钥并复制到集群,包括 namenode

#### (5) 配置 core-site.xml、hdfs-site.xml、workers 和 hadoop-env.sh

在 core-site.xml 设置 fs.defaultFS

在 hdfs-site.xml 设置 dfs.replication 、 dfs.namenode.name.dir 、 dfs.datanode.data.dir 和 dfs.namenode.secondary.http-address

在 workers 设置 datanode 的主机名

在 hadoop-env.sh 追加环境变量。

- (6) 在 datanode 上进行(1)(2)(3)(5)步。
- (7) 配置 namenode 和 datanode 的 host 文件
- (8) 格式化 NameNode

在 NameNode 上执行格式化命令,只需执行一次

(9) 启动 Hadoop 集群

在 NameNode 执行启动命令

## (10) 验证集群状态

在 NameNode 查看集群健康状态

2 通过 HDFS 的 Shell 客户端,掌握对 HDFS 所提供的文件接口的操作能力。

此部分包括 hadoop 常用命令的实操,如 hadoop fs -ls / -mkdir / -rm / cat 等。

3 设计一个实验方案, 以验证 HDFS 的组成架构和文件块大小等核心概念。

#### 3.1 组成架构

(1) 使用 hdfs dfs -ls 验证 NameNode

这一操作说明 NameNode 能够查询文件系统的元数据来获取目录列表。

(2) 使用 hdfs dfs -mkdir 创建目录

这证明了 NameNode 能够接收更改并更新文件系统的元数据。

#### (3) 使用 hdfs dfs -put 上传文件

这需要 DataNode 存储数据块,而 NameNode 则需要更新关于这些数据块的元数据。

#### 3.2 文件块大小

#### (1) 查看当前文件块大小

使用 hdfs getconf -confKey dfs.blocksize 命令

## (2) 上传文件到 HDFS, 记录上传时间

使用如下命令, dd 创建一个 1GB 文件, 上传到 hdfs 并记录时间

```
dd if=/dev/zero of=1GB.bin bs=1G count=1
START=$(date +%s%N)
hadoop fs -put 1GB.bin /
END=$(date +%s%N)
UPLOAD_TIME=$(awk "BEGIN {print ($END - $START)/1000000}")
echo "Upload time: $UPLOAD_TIME ms"
```

#### (3) 修改块大小

在/usr/local/hadoop/etc/hadoop/hdfs-site.xml 添加以下内容:

重启 Hadoop

使用 hdfs getconf -confKey dfs.blocksize 验证更改

#### (4) 再次上传文件到 HDFS, 记录上传时间

## 模块二 HDFS 的 Java 客户端 API 编程

1、HDFS的 JAVA 客户端环境准备。

此部分在模块一有所体现,包括安装 temurin-8-jdk,设置 JAVA\_HOME 以及在 core-site.xml 中设置 fs.defaultFS 属性等。

- 2、通过 HDFS 的 JAVA 客户端,掌握对 HDFS 的编程接口 API 对文件的操作能力
  - (1) 在 IDEA 中新建 Java Maven JDK1.8 项目,设置 pom.xml 添加依赖:
  - (2) 创建 HdfsClient 类测试连接
- 3、设计一个实验方案,通过 HDFS 的 API 操作,实现文件上传、文件下载、文件夹删除、文件名更改、文件和文件夹判断,以及用 I/O 流操作 HDFS。
- 3.1 文件上传

```
public void uploadFile(String source, String destination) throws Exception
{
    FileSystem fs = getFileSystem();
    fs.copyFromLocalFile(new Path(source), new Path(destination));
    fs.close();
}
```

#### 3.2 文件下载

```
public void downloadFile(String hdfsPath, String localPath) throws
Exception {
    FileSystem fs = getFileSystem();
    fs.copyToLocalFile(new Path(hdfsPath), new Path(localPath));
    fs.close();
}
```

#### 3.3 文件夹删除

```
public void deleteDirectory(String directory) throws Exception {
   FileSystem fs = getFileSystem();
   fs.delete(new Path(directory), true); // true 表示递归删除
   fs.close();
}
3.4 文件名更改
public void renameFile(String source, String destination) throws Exception
{
   FileSystem fs = getFileSystem();
   fs.rename(new Path(source), new Path(destination));
   fs.close();
}
3.5 文件和文件夹判断
public void checkFileOrDirectory(String path) throws Exception {
   FileSystem fs = getFileSystem();
   FileStatus status = fs.getFileStatus(new Path(path));
   if (status.isDirectory()) {
       System.out.println(path + " 是一个文件夹");
   } else {
       System.out.println(path + " 是一个文件");
   fs.close();
```

#### 3.6 I/O 流操作 HDFS

#### (1) 文件上传

}

```
public void putFileToHDFS() throws Exception {
    // 1. 获取对象
    Configuration conf = new Configuration();
    FileSystem fs = FileSystem.get(new
URI("hdfs://namenode.vayki.com:59000"), conf, "root");
    // 2. 输入流
    FileInputStream fis = new FileInputStream(new File("testio.txt"));
    // 3. 输出流
```

```
FSDataOutputStream fos = fs.create(new Path("/testio.txt"));
   // 4. 输入输出流相互拷贝
   IOUtils.copyBytes(fis, fos, conf);
   // 5. 关闭流
   IOUtils.closeStream(fos);
   IOUtils.closeStream(fis);
   fs.close();
}
 (2) 文件下载
public void getFileFromHDFS() throws IOException, InterruptedException,
URISyntaxException {
   // 1. 创建配置对象
   Configuration conf = new Configuration();
   FileSystem fs = FileSystem.get(new
URI("hdfs://namenode.vayki.com:59000"), conf, "root");
   // 2. 输入流
   FSDataInputStream fis = fs.open(new Path("/testio.txt"));
   // 3. 输出流
   FileOutputStream fos = new FileOutputStream(new File("testio1.txt"));
   // 4. 流互拷贝
   IOUtils.copyBytes(fis, fos, conf);
   // 5. 关闭流对象
   IOUtils.closeStream(fos);
   IOUtils.closeStream(fis);
   fs.close();
}
 (3) 定位文件读取
@Test
/**
 * 下载第1块内容
 */
public void readFileSeek1() throws IOException,
InterruptedException, URISyntaxException {
   // 1. 获取对象
   Configuration conf = new Configuration();
   FileSystem fs = FileSystem.get(new
URI("hdfs://namenode.vayki.com:59000"), conf, "root");
   // 2. 获取输入流
   FSDataInputStream fis = fs.open(new
Path("/hadoop-3.3.6.tar.gz"));
```

```
// 3. 获取输出流
   FileOutputStream fos = new FileOutputStream(new
File("hadoop-3.3.6.tar.gz.part1"));
   // 4. 流的互拷贝(这里只拷贝指定大小的数据流 128M)
   byte[] buffer = new byte[1024];
   for (int i = 0; i < 1024 * 128; i++) {
       fis.read(buffer);
      fos.write(buffer);
   }
   // 5. 关闭资源
   IOUtils.closeStream(fos);
   IOUtils.closeStream(fis);
   fs.close();
}
/**
* 下载第2块内容
*/
@Test
public void readFileSeek2() throws IOException,
InterruptedException, URISyntaxException {
   // 1. 获取对象
   Configuration conf = new Configuration();
   FileSystem fs = FileSystem.get(new
URI("hdfs://namenode.vayki.com:59000"), conf, "root");
   // 2. 获取输入流
   FSDataInputStream fis = fs.open(new
Path("/hadoop-3.3.6.tar.gz"));
   // 3. 指定输入流读取位置
   fis.seek(1024*1024*128);
   // 4. 获取输出流
   FileOutputStream fos = new FileOutputStream(new
File("hadoop-3.3.6.tar.gz.part2"));
   // 5. 流的互拷贝
   IOUtils.copyBytes(fis, fos, conf);
   // 6. 关闭资源
   IOUtils.closeStream(fos);
   IOUtils.closeStream(fis);
   fs.close();
}
合并文件
cat hadoop-3.3.6.tar.gz.part2 >> hadoop-3.3.6.tar.gz.part1
合并完成后进行解压和哈希值比对, 发现与源文件相同。
```

## 四、实验效果及结果分析:

(对模块一,要求能够验证 HDFS 的组成架构和文件块大小等核心概念,对模块二通,要求过对 HDFS 写数据流的流程知识,详细分析自已实验方案中"文件写入"过程及所获得的结果)

## 模块一 HDFS 的 Shell 客户端操作

#### 1 完成 HDFS 环境搭建

以 Debian 12 为例

## (1) 安装 JDK8

```
使用 adoptium 源安装 temurin-8-jdk sudo apt-get install -y wget apt-transport-https gnupg wget -O - https://packages.adoptium.net/artifactory/api/gpg/key/public | sudo apt-key add - echo "deb https://packages.adoptium.net/artifactory/deb $(lsb_release -sc) main" | sudo tee /etc/apt/sources.list.d/adoptium.list sudo apt-get update sudo apt-get install temurin-8-jdk
```

#### (2) 设置环境变量

```
包括 JAVA_HOME、HADOOP_HOME 和 PATH echo 'export JAVA_HOME=/usr/lib/jvm/temurin-8-jdk-amd64' >> ~/.bashrc echo 'export HADOOP_HOME=/usr/local/hadoop' >> ~/.bashrc echo 'export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin' >> ~/.bashrc source ~/.bashrc
```

#### (3) 下载 Hadoop

下载并解压 hadoop-3.3.6

#### wget

```
https://dlcdn.apache.org/hadoop/common/hadoop-3.3.6/hadoop-3.3.6.tar.gz sudo tar zxvf hadoop-3.3.6.tar.gz -C /usr/local/ sudo mv /usr/local/hadoop-3.3.6 /usr/local/hadoop rm hadoop-3.3.6.tar.gz
```

#### (4)配置 SSH 免密登录

ssh-keygen -t rsa -P ''

使用 ssh-keygen 生成密钥并复制到集群,包括 namenode

```
ssh-copy-id -p 2200 root@namenode.vayki.com
ssh-copy-id -p 2200 root@datanode1.vayki.com
ssh-copy-id -p 2200 root@datanode2.vayki.com
这里使用了 SSH 非标准端口,还需编辑~/.ssh/config 文件以配置 hadoop 正常
运行。
vim ~/.ssh/config
填入以下内容:
Host namenode.vayki.com
HostName namenode.vayki.com
Port 2200
User root
Host datanode1.vayki.com
HostName datanode1.vayki.com
Port 2200
User root
Host datanode2.vayki.com
HostName datanode2.vayki.com
Port 2200
User root
然后更改权限 600 以保证安全
chmod 600 ~/.ssh/config
 (5) 配置 core-site.xml、hdfs-site.xml、workers 和 hadoop-env.sh
在 core-site.xml 设置 fs.defaultFS:
vim /usr/local/hadoop/etc/hadoop/core-site.xml
   cproperty>
       <name>fs.defaultFS</name>
       <value>hdfs://namenode.vayki.com:59000</value>
   </property>
   hdfs-site.xml 设置 dfs.replication 、 dfs.namenode.name.dir 、
dfs.datanode.data.dir 和 dfs.namenode.secondary.http-address:
vim /usr/local/hadoop/etc/hadoop/hdfs-site.xml
   cproperty>
```

```
<name>dfs.replication</name>
       <value>2</value>
   </property>
   cproperty>
       <name>dfs.namenode.name.dir</name>
       <value>file:///usr/local/hadoop/hdfs/namenode</value>
   </property>
   cproperty>
       <name>dfs.datanode.data.dir</name>
       <value>file:///usr/local/hadoop/hdfs/datanode</value>
   </property>
   cproperty>
       <name>dfs.namenode.secondary.http-address</name>
       <value>namenode.vayki.com:50090</value>
   </property>
在 workers 设置 datanode 的主机名
vim /usr/local/hadoop/etc/hadoop/workers
datanode1.vayki.com
datanode2.vayki.com
在 hadoop-env.sh 追加环境变量。
echo 'export HDFS NAMENODE USER=root' >>
/usr/local/hadoop/etc/hadoop/hadoop-env.sh
echo 'export HDFS DATANODE USER=root' >>
/usr/local/hadoop/etc/hadoop/hadoop-env.sh
echo 'export HDFS_SECONDARYNAMENODE_USER=root' >>
/usr/local/hadoop/etc/hadoop/hadoop-env.sh
echo 'export YARN_RESOURCEMANAGER_USER=root' >>
/usr/local/hadoop/etc/hadoop/hadoop-env.sh
echo 'export YARN_NODEMANAGER_USER=root' >>
/usr/local/hadoop/etc/hadoop/hadoop-env.sh
echo 'export JAVA_HOME=/usr/lib/jvm/temurin-8-jdk-amd64' >>
/usr/local/hadoop/etc/hadoop/hadoop-env.sh
source /usr/local/hadoop/etc/hadoop/hadoop-env.sh
 (6) 在 DataNode 上进行(1)(2)(3)(5)步。
 (7) 配置 NameNode 和 DataNode 的 hosts 文件
vim /etc/hosts
127.0.0.1 localhost
154.9.239.202 namenode.vayki.com namenode
185.212.62.40 datanode1.vayki.com datanode1
82.115.31.90 datanode2.vayki.com datanode2
```

#### (8) 格式化 NameNode

在 NameNode 上执行格式化命令,只需执行一次 hdfs namenode -format

#### (9) 启动 Hadoop 集群

在 NameNode 执行启动命令 start-dfs.sh

#### (10) 验证集群状态

在 NameNode 查看集群健康状态

hdfs dfsadmin -report

```
root@namenode:~# start-dfs.sh
Starting namenodes on [namenode.vayki.com]
Starting datanodes
Starting secondary namenodes [namenode.vayki.com]
root@namenode:~# hdfs dfsadmin -report
Safe mode is ON
Configured Capacity: 19999629312 (18.63 GB)
Present Capacity: 7336898560 (6.83 GB)
DFS Remaining: 5865086976 (5.46 GB)
DFS Used: 1471811584 (1.37 GB)
DFS Used%: 20.06%
Replicated Blocks:
       Under replicated blocks: 1
        Blocks with corrupt replicas: 0
       Missing blocks: 0
        Missing blocks (with replication factor 1): 0
       Low redundancy blocks with highest priority to recover: 0
        Pending deletion blocks: 0
Erasure Coded Block Groups:
       Low redundancy block groups: 0
        Block groups with corrupt internal blocks: 0
        Missing block groups: 0
        Low redundancy blocks with highest priority to recover: 0
        Pending deletion blocks: 0
```

```
Live datanodes (2):
Name: 185.212.62.40:9866 (datanodel.vayki.com)
Hostname: datanodel.vayki.com
Decommission Status : Normal
Configured Capacity: 10017955840 (9.33 GB)
DFS Used: 735899648 (701.81 MB)
Non DFS Used: 4703031296 (4.38 GB)
DFS Remaining: 4119486464 (3.84 GB)
DFS Used%: 7.35%
DFS Remaining%: 41.12%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
Xceivers: 0
Last contact: Mon Apr 08 12:00:18 UTC 2024
Last Block Report: Mon Apr 08 12:00:15 UTC 2024
Num of Blocks: 9
Name: 82.115.31.90:9866 (datanode2.vayki.com)
Hostname: datanode2.vayki.com
Decommission Status : Normal
Configured Capacity: 9981673472 (9.30 GB)
DFS Used: 735911936 (701.82 MB)
Non DFS Used: 7027138560 (6.54 GB)
DFS Remaining: 1745600512 (1.63 GB)
DFS Used%: 7.37%
DFS Remaining%: 17.49%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
```

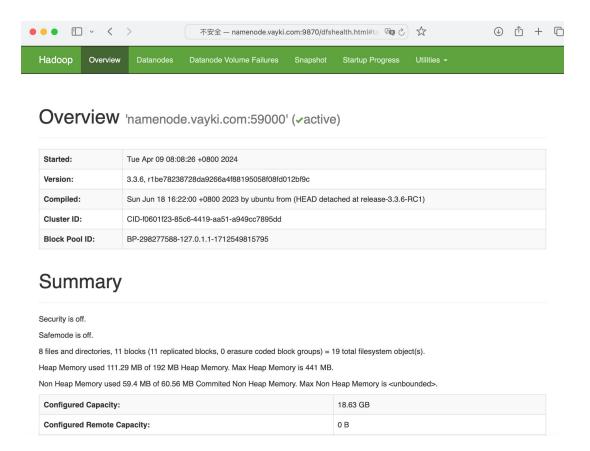
浏览器打开 http://namenode.vayki.com:9870/ 即可访问 Web UI。

Last contact: Mon Apr 08 12:00:20 UTC 2024

Last Block Report: Mon Apr 08 12:00:11 UTC 2024

Xceivers: 0

Num of Blocks: 9



# 2 通过 HDFS 的 Shell 客户端,掌握对 HDFS 所提供的文件接口的操作能力。

此部分包括 hadoop 常用命令的实操,如 hadoop fs -ls / -mkdir / -rm / cat 等。

常用命令	运行结果
	root@namenode:~# hadoop fs —Is /
	Found 2 items
列出目录	drwx root supergroup 0 2024-04-06 08:25 /tmp
内容	drwxr-xr-x - root supergroup 0 2024-04-06 08:25 /user
创建目录	root@namenode:~# hadoop fs -mkdir /directory
	root@namenode:~# hadoop fs -rm -r /directory 24/04/06 08:46:47 INFO fs.TrashPolicyDefault: Namenode trash configuration: Deletion interval = 0 minutes, Emptier interval = 0 minutes.
删除目录	Deleted /directory

```
root@namenode:~# touch localfile
         root@namenode:~# hadoop fs -put localfile /
         root@namenode:~# hadoop fs -ls /
         Found 3 items
         -rw-r--r-- 2 root supergroup 0 2024-04-06 08:48
上传本地
         /localfile
         drwx---- - root supergroup
文件到
                                             0 2024-04-06 08:25 /tmp
HDFS
                                           0 2024-04-06 08:25 /user
         drwxr-xr-x - root supergroup
         root@namenode: "# rm localfile
从 HDFS
         root@namenode:~# hadoop fs -get / localfile
复制文件
         root@namenode:~# Is
到本地
         1.txt hdfs input localfile run-wordcount.sh start-hadoop.sh
         root@namenode: "# hadoop fs -cp /localfile /copyfile
         root@namenode:~# hadoop fs -ls /
         Found 4 items
         -rw-r--r-- 2 root supergroup 0 2024-04-06 08:51
         /copyfile
         -rw-r--r 2 root supergroup 0 2024-04-06 08:48
         /localfile
         drwx---- - root supergroup
                                             0 2024-04-06 08:25 /tmp
         drwxr-xr-x - root supergroup 0 2024-04-06 08:25 /user
复制文件
         root@namenode: "# hadoop fs -mv /localfile /movefile
         root@namenode: "# hadoop fs -ls /
         Found 4 items
         -rw-r--r-- 2 root supergroup
                                            0 2024-04-06 08:51
         /copyfile
         -rw-r--r-- 2 root supergroup
                                            0 2024-04-06 08:48
         /movefile
         drwx----- - root supergroup 0 2024-04-06 08:25 /tmp
         drwxr-xr-x - root supergroup 0 2024-04-06 08:25 /user
移动文件
         root@namenode:~# hadoop fs -cat /hello
查看文件
         Hello, hadoop!
更改文件
或目录的
权限
         root@namenode:~# hadoop fs -chmod 755 /hello
统计目录
中的文件
数量和占
         root@namenode:~# hadoop fs -count /
                               10 156456 /
用空间
                   13
设置文件
         root@namenode:~# hadoop fs -setrep 5 /hello
的副本数
         Replication 5 set: /hello
```

量

3 设计一个实验方案, 以验证 HDFS 的组成架构和文件块大小等核心概念。

#### 3.1 组成架构

#### (1) 使用 hdfs dfs -ls 验证 NameNode

这一操作说明 NameNode 能够查询文件系统的元数据来获取目录列表。

#### (2) 使用 hdfs dfs -mkdir 创建目录

这证明了 NameNode 能够接收更改并更新文件系统的元数据。

## (3) 使用 hdfs dfs -put 上传文件

这需要 DataNode 存储数据块,而 NameNode 则需要更新关于这些数据块的元数据。

```
-rw-r--r-- 2 root supergroup 5 2024-04-08 04:38 /2.txt
-rw-r--r-- 2 root supergroup 4 2024-04-08 12:08 /789
drwxr-xr-x - root supergroup 0 2024-04-08 12:07 /dir
-rw-r--r-- 2 root supergroup 730107476 2024-04-08 10:00
/hadoop-3.3.6.tar.gz
-rw-r--r-- 3 root supergroup 6 2024-04-08 09:46 /testio.txt
```

#### 3.2 文件块大小

## (1) 查看当前文件块大小

使用 hdfs getconf -confKey dfs.blocksize 命令
root@namenode:~# hdfs getconf -confKey dfs.blocksize
134217728

#### (2) 上传文件到 HDFS, 记录上传时间

使用如下命令, dd 创建一个 1GB 文件, 上传到 hdfs 并记录时间

```
dd if=/dev/zero of=1GB.bin bs=1G count=1
START=$(date +%s%N)
hadoop fs -put 1GB.bin /
END=$(date +%s%N)
UPLOAD_TIME=$(awk "BEGIN {print ($END - $START)/1000000}")
echo "Upload time: $UPLOAD_TIME ms"

root@namenode:~# START=$(date +%s%N)
root@namenode:~# hadoop fs -put 1GB.bin /
root@namenode:~# END=$(date +%s%N)
root@namenode:~# UPLOAD_TIME=$(awk "BEGIN {print ($END - $START)/1000000}")
root@namenode:~# echo "Upload time: $UPLOAD_TIME ms"
Upload time: 4902.21 ms
```

#### (3) 修改块大小

在/usr/local/hadoop/etc/hadoop/hdfs-site.xml 添加以下内容:

#### 重启 Hadoop

/usr/local/hadoop/sbin/stop-dfs.sh

```
/usr/local/hadoop/sbin/start-dfs.sh
使用 hdfs getconf -confKey dfs.blocksize 验证更改
```

root@namenode:~# hdfs getconf -confKey dfs.blocksize
1048576

#### (4) 再次上传文件到 HDFS, 记录上传时间

```
可见当文件块过小时,上传时间显著增加root@namenode:~# START=$(date +%s%N)root@namenode:~# hadoop fs -put 1GB.bin /root@namenode:~# END=$(date +%s%N)root@namenode:~# UPLOAD_TIME=$(awk "BEGIN {print ($END - $START)/1000000}")root@namenode:~# echo "Upload time: $UPLOAD_TIME ms"Upload time: 10947.8 ms
```

## 模块二 HDFS 的 Java 客户端 API 编程

1、HDFS的 JAVA 客户端环境准备。

此部分在模块一有所体现,包括安装 temurin-8-jdk,设置 JAVA\_HOME 以及在 core-site.xml 中设置 fs.defaultFS 属性等。

- 2、通过 HDFS 的 JAVA 客户端,掌握对 HDFS 的编程接口 API 对文件的操作能力
  - (1) 在 IDEA 中新建 Java Maven JDK1.8 项目,设置 pom.xml 添加依赖:

```
<groupId>org.apache.hadoop</groupId>
        <artifactId>hadoop-common</artifactId>
        <version>2.7.2
    </dependency>
    <dependency>
        <groupId>org.apache.hadoop</groupId>
        <artifactId>hadoop-client</artifactId>
        <version>2.7.2
    </dependency>
    <dependency>
        <groupId>org.apache.hadoop</groupId>
        <artifactId>hadoop-hdfs</artifactId>
        <version>2.7.2
    </dependency>
</dependencies>
 (2) 创建 HdfsClient 类测试连接
public class HdfsClient {
   @Test
    public void check() throws Exception {
//
          uploadFile("hello.txt", "/hello.txt");
        printFileList("/");
    }
    public FileSystem getFileSystem() throws Exception {
        Configuration configuration = new Configuration();
        String fileSystemURL = "hdfs://namenode.vayki.com:59000";
        return FileSystem.get(new URI(fileSystemURL), configuration,
"root");
✓ 測试 已通过: 1共 1 个測试 – 3秒 220毫秒
/Users/nanmener/Library/Java/JavaVirtual Machines/corretto-1.8.0\_382/Contents/Home/bin/java \dots \\
2024-04-08 20:18:02,147 WARN [org.apache.hadoop.util.NativeCodeLoader] - Unable to load native-hadoop
 library for your platform... using builtin-java classes where applicable
1234
2.txt
789
hadoop-3.3.6.tar.gz
testio.txt
```

3、设计一个实验方案,通过 HDFS 的 API 操作,实现文件上传、文件下载、文件夹删除、文件名更改、文件和文件夹判断,以及用 I/O 流操作 HDFS。

#### 3.1 文件上传

```
public void uploadFile(String source, String destination) throws Exception
{
    FileSystem fs = getFileSystem();
    fs.copyFromLocalFile(new Path(source), new Path(destination));
    fs.close();
}
```

#### 3.2 文件下载

```
public void downloadFile(String hdfsPath, String localPath) throws
Exception {
    FileSystem fs = getFileSystem();
    fs.copyToLocalFile(new Path(hdfsPath), new Path(localPath));
    fs.close();
}
```

#### 3.3 文件夹删除

```
public void deleteDirectory(String directory) throws Exception {
   FileSystem fs = getFileSystem();
   fs.delete(new Path(directory), true); // true 表示递归删除
   fs.close();
}
```

#### 3.4 文件名更改

```
public void renameFile(String source, String destination) throws Exception
{
    FileSystem fs = getFileSystem();
    fs.rename(new Path(source), new Path(destination));
    fs.close();
}
```

#### 3.5 文件和文件夹判断

```
public void checkFileOrDirectory(String path) throws Exception {
   FileSystem fs = getFileSystem();
   FileStatus status = fs.getFileStatus(new Path(path));
   if (status.isDirectory()) {
```

```
System.out.println(path + " 是一个文件夹");
    } else {
        System.out.println(path + " 是一个文件");
    }
    fs.close();
}
                 public class HdfsClient {
          14 6
          15
                    @Test
                     public void check() throws Exception {
          16 6
                        uploadFile( source: "hello.txt", destination: "/hello.txt");
          17
                        printFileList( directoryPath: "/");
                        downloadFile( hdfsPath: "/1234", localPath: "456.txt");
          19
          20
                        deleteDirectory("/hello.txt");
                        printFileList( directoryPath: "/");
          21
                        renameFile( source: "/1234", destination: "/123");
                        printFileList( directoryPath: "/");
          23
                        checkFileOrDirectory( path: "/");
          24
                        checkFileOrDirectory( path: "/2.txt");
          25
                    }-
    ✓ 測试 已通过: 1共 1 个测试 – 27秒 303毫秒
    2024-04-08 20:27:15,107 WARN [org.apache.hadoop.util.NativeCodeLoader] - Unable
     library for your platform... using builtin-java classes where applicable
    1234
    2.txt
    789
    hadoop-3.3.6.tar.gz
    hello.txt
    testio.txt
    1234
    2.txt
    789
    dir
3.6 I/O 流操作 HDFS
 (1) 文件上传
public void putFileToHDFS() throws Exception {
    // 1. 获取对象
    Configuration conf = new Configuration();
    FileSystem fs = FileSystem.get(new
URI("hdfs://namenode.vayki.com:59000"), conf, "root");
    // 2. 输入流
    FileInputStream fis = new FileInputStream(new File("testio.txt"));
```

// 3. 输出流

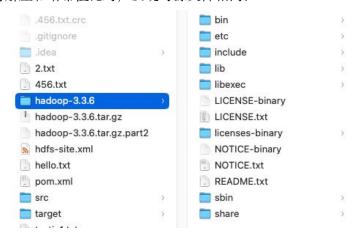
```
FSDataOutputStream fos = fs.create(new Path("/testio.txt"));
   // 4. 输入输出流相互拷贝
   IOUtils.copyBytes(fis, fos, conf);
   // 5. 关闭流
   IOUtils.closeStream(fos);
   IOUtils.closeStream(fis);
   fs.close();
}
 (2) 文件下载
public void getFileFromHDFS() throws IOException, InterruptedException,
URISyntaxException {
   // 1. 创建配置对象
   Configuration conf = new Configuration();
   FileSystem fs = FileSystem.get(new
URI("hdfs://namenode.vayki.com:59000"), conf, "root");
   // 2. 输入流
   FSDataInputStream fis = fs.open(new Path("/testio.txt"));
   // 3. 输出流
   FileOutputStream fos = new FileOutputStream(new File("testio1.txt"));
   // 4. 流互拷贝
   IOUtils.copyBytes(fis, fos, conf);
   // 5. 关闭流对象
   IOUtils.closeStream(fos);
   IOUtils.closeStream(fis);
   fs.close();
}
 (3) 定位文件读取
@Test
/**
 * 下载第1块内容
 */
public void readFileSeek1() throws IOException,
InterruptedException, URISyntaxException {
   // 1. 获取对象
   Configuration conf = new Configuration();
   FileSystem fs = FileSystem.get(new
URI("hdfs://namenode.vayki.com:59000"), conf, "root");
   // 2. 获取输入流
   FSDataInputStream fis = fs.open(new
Path("/hadoop-3.3.6.tar.gz"));
```

```
// 3. 获取输出流
   FileOutputStream fos = new FileOutputStream(new
File("hadoop-3.3.6.tar.gz.part1"));
   // 4. 流的互拷贝(这里只拷贝指定大小的数据流 128M)
   byte[] buffer = new byte[1024];
   for (int i = 0; i < 1024 * 128; i++) {
       fis.read(buffer);
      fos.write(buffer);
   }
   // 5. 关闭资源
   IOUtils.closeStream(fos);
   IOUtils.closeStream(fis);
   fs.close();
}
/**
* 下载第2块内容
*/
@Test
public void readFileSeek2() throws IOException,
InterruptedException, URISyntaxException {
   // 1. 获取对象
   Configuration conf = new Configuration();
   FileSystem fs = FileSystem.get(new
URI("hdfs://namenode.vayki.com:59000"), conf, "root");
   // 2. 获取输入流
   FSDataInputStream fis = fs.open(new
Path("/hadoop-3.3.6.tar.gz"));
   // 3. 指定输入流读取位置
   fis.seek(1024*1024*128);
   // 4. 获取输出流
   FileOutputStream fos = new FileOutputStream(new
File("hadoop-3.3.6.tar.gz.part2"));
   // 5. 流的互拷贝
   IOUtils.copyBytes(fis, fos, conf);
   // 6. 关闭资源
   IOUtils.closeStream(fos);
   IOUtils.closeStream(fis);
   fs.close();
}
```

```
public void readFileSeek1() throws IOException, InterruptedException, URISyntaxException
      69
                      // 1. 获取对象
      70
                      Configuration conf = new Configuration();
                      FileSystem fs = FileSystem.get(new URI( str: "hdfs://namenode.vayki.com:59000"), conf,
      71
      72
                      // 2.获取输入流
                      FSDataInputStream fis = fs.open(new Path( pathString: "/hadoop-3.3.6.tar.gz"));
      73
                      // 3. 获取输出流
      74
                      FileOutputStream fos = new FileOutputStream(new File( pathname: "hadoop-3.3.6.tar.gz
      75
                       .part1"));
      76
                      // 4. 流的互拷贝 (这里只拷贝指定大小的数据流128M)
      77
                      byte[] buffer = new byte[1024];
      78
                      for (int \underline{i} = 0; \underline{i} < 1024 * 128; \underline{i} + +) {
      79
                          fis.read(buffer);
      80
                          fos.write(buffer);
      81
                                                                                                             zů
✓ 測试 已通过: 1共 1 个測试 - 14秒 691毫秒
/Users/nanmener/Library/Java/JavaVirtualMachines/corretto-1.8.0_382/Contents/Home/bin/java \dots
2024-04-08 20:44:25,538 WARN [org.apache.hadoop.util.NativeCodeLoader] - Unable to load native-hadoop
 library for your platform... using builtin-java classes where applicable
进程已结束, 退出代码为 0
```

#### 合并文件

cat hadoop-3.3.6.tar.gz.part2 >> hadoop-3.3.6.tar.gz.part1 合并完成后进行解压和哈希值比对,发现与源文件相同。



## 4、通过对 HDFS 写数据流的流程知识,详细分析自已实验方案中"文件写入"的过程。

文件写入的流程包括:

- 1) 客户端通过 Distributed FileSystem 模块向 NameNode 请求上传文件, NameNode 检查目标文件是否已存在, 父目录是否存在。
- 2) NameNode 返回是否可以上传。
- 3) 客户端请求第一个 block 上传到哪几个 datanode 服务器上。
- 4) NameNode 返回 2 个 datanode 节点, 分别为 datanode1、datanode2。
- 5) 客户端通过 FSDataOutputStream 模块请求 datanode1 上传数据, datanode1 收到请求

会继续调用 datanode2. 将这个通信管道建立完成。

- 6) datanode1、datanode2 逐级应答客户端。
- 7)客户端开始往 datanode1 上传第一个 block (先从磁盘读取数据放到一个本地内存缓存), 以 packet 为单位, datanode1 收到一个 packet 就会传给 datanode2;
- 8) 当一个 block 传输完成之后,客户端再次请求 NameNode 上传第二个 block 的服务器。 (重复执行 3-7 步)。

## 五、结论

本次实验完成了 HDFS 基本操作及 API 编程的学习目标。通过两个主要模块的深入探索,理解 HDFS 的核心概念和架构,掌握如何通过 Hadoop 命令和 Java API 进行有效的文件系统操作。

在模块一中,通过在 Debian 12 环境下搭建 HDFS 并配置必要的环境变量和文件系统参数,验证 HDFS 的组成架构和文件块大小等核心概念。实验过程包括 SSH 免密登录配置、core-site.xml 和 hdfs-site.xml 的设置,Hadoop 集群的启动和验证。通过这些步骤加深对 HDFS 架构的理解,通过 Shell 客户端操作掌握 对 HDFS 文件接口的操作能力。这一模块的实践验证了 HDFS 的高可靠性和高扩展性特性。

在模块二中, 通过 HDFS 的 Java 客户端 API 编程了解如何利用 HDFS 的编程接口 API 进行文件操作。通过设置 Maven 依赖和编写 Java 测试类,实现文件上传、下载、文件夹删除、文件名更改、文件和文件夹判断,以及使用 I/O 流操作HDFS 的功能。详细分析文件写入的流程,从客户端请求上传文件到 NameNode,再到数据的实际存储在 DataNode 上,整个过程揭示了 HDFS 的数据流转机制,体现 HDFS 的设计哲学和高效性。

本次实验遇到的问题与解决方式:

(1) 开始试图使用 docker 搭建 hadoop 集群,发现

https://hub.docker.com/r/rancher/hadoop-base 在8年前停止更新,遂寻找新的镜像,找到了 https://hub.docker.com/r/apache/hadoop 镜像,发现其不提供 arm 版本镜像,无法在 M1 Macbook 上运行。

后找到 https://github.com/kiwenlau/hadoop-cluster-docker 项目,通过修改 Dockerfile 可以构建 arm 架构的镜像。发现该项目使用 jdk7,于是修改 Dockerfile,升级 ubuntu 版本并使用 jdk8。成功构建了 arm64 jdk8 的镜像,并发布到 https://hub.docker.com/r/chen2438/hadoop/tags。

但在使用 Java API 时,发现 Macbook 宿主机无法通过 docker 网络访问容器 (无法 ping 通) ,两者是隔离的。问题详见

https://www.cnblogs.com/luo-c/p/15830769.html , 在搜索解决方案后, 决定 放弃使用 M1 Macbook + Docker 环境, 搭建真实的 hadoop 集群。

- (2) 在搭建真实的 hadoop 集群时遇到的问题:
- Debian12 官方源中已不支持 JDK11,而 hadoop 3.3.6 需要 JDK8(编译&运行)或 JDK11(运行)。于是引入第三方源 adoptium。
- 2. 使用的三台公网服务器使用 SSH 非标准端口 2200, 在 hadoop 运行前需要编辑~/.ssh/config 文件。
- 3. 在使用 rsync 复制 hadoop 分发到 datanode 时操作不当, 导致 Incompatible clusterIDs 报错, 清楚 datanode 的数据目录后解决。
- 4. 由于主机名和 hosts 文件设置不当,导致 Datanode denied communication with namenode 报错,正确配置后解决。