

摘 要

随着数字时尚产业和电子商务快速发展，虚拟试穿、数字化服饰设计以及在线内容生成等应用对高质量的纹理迁移技术提出了更高要求。服饰纹理替换既要做到纹理风格的精准迁移，又需尽可能保留原始服饰的几何结构、褶皱细节和材质光影关系。然而，现有图像处理和生成式重绘方法普遍存在结构失真、纹理接缝伪影及材质融合不自然等问题。针对上述问题，本文设计并实现了一套基于扩散模型的服饰纹理智能重绘算法与系统，命名为 iRetexturing。

本文提出了融合语义分割、空间约束与连续性扩展策略的服饰纹理重绘算法。该算法首先利用 Segment Anything Model (SAM) 对输入服饰图像进行像素级区域分割，然后通过“四方连续性”策略对目标纹理进行无缝扩展，以消除大面积平铺时的边界裂缝。接着，以 SDXL 作为生成基座，引入 ControlNet 的 Canny 边缘检测与 Depth Anything V2 深度估计作为双重空间约束，在重绘过程中增强对服饰结构（如衣领、袖口、褶皱）的保持能力。实验结果表明，该方法在服饰纹理替换任务中取得了良好效果：生成图像的结构相似性 (SSIM) 达到 0.8323，感知相似度 (LPIPS) 达到 0.1385，整体性能优于传统方法。

本文搭建了一套基于 Next.js 的智能重绘 Web 系统。系统采用 Next.js 全栈框架，前端使用 React 构建交互界面，后端通过 Prisma ORM 管理数据，并集成 ComfyUI 作为推理引擎。在实现过程中，利用 API Routes 统一调度业务接口与推理任务，同时引入实时状态反馈机制，使用户能够顺畅地完成素材上传、参数设置、任务提交和结果管理。最终实现的系统为服饰纹理替换场景提供了一个可部署、可交互、可扩展的工程化方案。

关键词：服饰纹理替换；扩散模型；语义分割；空间约束；Next.js；智能重绘

Abstract

The rapid growth of digital fashion and e-commerce has escalated the demand for high-quality texture transfer in applications such as virtual try-on, digital garment design, and online content generation. Garment texture replacement must faithfully migrate texture style while preserving the original geometric structure, wrinkle details, and material shading. However, existing image processing and generative inpainting methods commonly suffer from structural distortion, seam artifacts, and unnatural material blending. To address these challenges, this paper presents iRetexturing, a diffusion model-based intelligent garment retexturing algorithm and system.

The proposed algorithm integrates semantic segmentation, spatial constraints, and a continuity extension strategy. First, the Segment Anything Model (SAM) performs pixel-level garment region segmentation. A “four-directional continuity” strategy then enables seamless texture tiling to eliminate boundary discontinuities. Using SDXL as the generative backbone, ControlNet-based Canny edge detection and Depth Anything V2 depth estimation provide dual spatial constraints that enhance structural preservation of garment features such as collars, cuffs, and folds. Experimental results demonstrate strong performance on garment texture replacement, achieving a structural similarity (SSIM) of 0.8323 and a learned perceptual similarity (LPIPS) of 0.1385, outperforming conventional methods.

On the system side, a Next.js-based intelligent retexturing web platform is developed. The system adopts the Next.js full-stack framework with a React frontend, Prisma ORM for data management, and ComfyUI as the inference engine. API Routes orchestrate business logic and inference tasks, while real-time status feedback enables a seamless workflow covering asset upload, parameter configuration, task submission, and result management. The resulting system delivers a deployable, interactive, and extensible engineering solution for garment texture replacement.

Keywords: garment texture replacement; diffusion model; semantic segmentation; spatial constraints; Next.js; intelligent retexturing

目录

摘要

Abstract

第 1 章 绪论	1
1.1 研究目的与意义	1
1.2 研究现状与发展趋势综述	1
1.2.1 图像处理与生成对抗网络	1
1.2.2 基于扩散模型的生成式重绘	2
1.2.3 国内外研究现状分析	2
1.2.4 存在的问题与演进趋势	3
1.3 研究内容	3
第 2 章 服饰纹理替换的需求分析与功能设计	5
2.1 需求分析	5
2.1.1 系统需求分析	5
2.1.2 用户需求分析	6
2.2 系统设计	7
2.2.1 功能设计	7
2.2.2 数据库设计	8
第 3 章 服饰纹理替换的智能重绘方法原理	10
3.1 算法原理	10
3.1.1 算法概述	10
3.1.2 图像增强与预处理	11
3.1.3 四方连续纹理扩展	12
3.1.4 受几何约束引导的扩散重绘	14
3.2 实验设计与分析	15
3.2.1 实验环境	15

3.2.2	数据集准备	15
3.2.3	评价指标与基线方法	17
3.2.4	对比实验	18
3.2.5	消融实验	22
第 4 章	服饰纹理替换的智能重绘系统的设计与实现	26
4.1	系统总体设计	26
4.2	系统相关依赖和组件介绍	27
4.2.1	响应式用户编辑界面	28
4.2.2	管理员后台与安全性设计	28
4.3	系统演示	29
4.3.1	系统主页与用户登录注册	29
4.3.2	用户工作台与各功能界面	30
4.3.3	管理员工作台与各功能界面	33
第 5 章	总结与展望	35
5.1	总结	35
5.2	不足与展望	35
	致谢	40

1 绪论

1.1 研究目的与意义

随着电子商务在全球普及开来，数字时尚产业（Digital Fashion）也发展得很快，不管是网购里的虚拟试穿（Virtual Try-on），还是设计师做设计的时候快速更换原型，都迫切需要高质量、高保真度的纹理迁移技术^[1-2]。服装纹理替换（Fashion Item Retexture）是计算机视觉和图形学在时尚工业里最核心的应用之一，它的主要目标是：改变服装表面材质（比如纹理、图案、面料质感）的时候，把原单品的几何结构（比如褶皱、阴影、空间透视）完整保留下来^[3]。

过去很长一段时间里，传统的服饰纹理替换方法基本都要靠人工精细修改（比如用 Photoshop 做像素级调整），这种方法不仅干活慢效率低，还特别依赖专业美工的技术能力，没办法满足大规模、个性化的市场更新需求^[4]。早期做自动化尝试的时候，虽然多多少少做到了纹理映射，但处理复杂纹理、保留物理规律（比如布料垂坠感）这些方面，缺陷还是很明显。

本文要研究并且做出一套专门给服饰纹理替换用的智能重绘框架（iRetexturing）和配套系统。结合深度学习里的扩散模型（Diffusion Models）和几何先验引导技术，本文试着解决现在已有的生成式方法存在的几个瓶颈问题：几何保真度不够、边缘处理粗糙还有交互控制性弱等，这项研究不光能给服装设计师给出一站式的数字化原型创作工具，还能缩短从概念设计到做样衣的周期，同时放到电商领域里，高保真的纹理替换系统能明显提高消费者的购物体验，减少退货量，促进时尚产业往智能化、数字化方向走得更深。

1.2 研究现状与发展趋势综述

1.2.1 图像处理与生成对抗网络

早期探索大多集中在基础的图像编辑和颜色调整工作上，虽然初步做到了设计灵活，但没法在真实感和物理一致性之间找到平衡，处理复杂褶皱和光影的自然过渡时效果不太好，深度学习快速发展起来后，生成对抗网络（GANs）^[5]一度变成时尚视觉生成领域里的主流框架，还大大促进了服装设计和渲染的自动化发展，这段时间里，研究人员提出了不少带创新性的网络框架，用来解决服饰生成的特殊需求。比如 CTS-GAN 框架就做了创新，把服装的颜色、纹理和形状特征分开映射到独立的潜在空间中，做到了视觉属性有效分离，还能单独控制，这样一来哪怕是非专业人员，也能做出符合专业审美的服装设计，相关研究显示它在风格多样性指数（Style Diversity Index）上，提高了大

约 23%^[6]。同时，跨域特征融合框架（Cross-domain Feature Fusion）想缩小创作者意图和技术实现之间的差距，它改进了草图转服装的转换流程，不光提高了输出结果的保真度，还让传统设计流程的整体工作效率提高了差不多 37.6%。针对衣物穿搭的连贯性问题，DFDGAN 则加入特定对抗架构，优化了多类别服装合成的兼容性，通过对上下装这类组合特征加约束，不仅能合成风格高度统一的成套服饰，还把反映图像质量的 Fréchet Inception 距离（FID）指标降低了 15.2%^[7]。另外，像 Quantum-GAN 这类前沿探索，甚至融合了特征降维跟进化策略做计算优化，在保留极高细节逼真度的同时，做到了削减高达 92% 的计算资源（比如量子位需求）。不过，虽说 GAN 类模型在自动化和特定属性生成上已经有了不少进步，这类模型还是受到自身固有对抗机制的很大限制。普遍存在训练过程特别不稳定、模式崩溃（Mode Collapse）这类严重问题，严重影响了输出样本分布的多样化拓展。更关键的是，GAN 模型在框架结构上缺少灵活性和自纠错能力，要是遇到超高分辨率纹理映射，或者需要做工业级精准的局部像素编辑时，它非线性的隐空间分布会让生成过程很难做细粒度的确定性控制，这就成了该技术在服饰纹理高保真替换任务里，很难突破的技术瓶颈^[8]。

1.2.2 基于扩散模型的生成式重绘

近些年，扩散模型（Diffusion Models）^[9-10]靠着其在概率去噪机制上的颠覆性创新^[11]，很快取代了传统方法，确定了图像可控合成与精细生成的新标杆，展现出比 GAN 系列方法更扎实的理论基础和应用潜力。从数学原理来分析，扩散模型采用的随机微分方程框架，本来就支持多阶段的逐步细化生成，这套机制不光能彻底避开对抗网络里常出现的模式崩溃问题，还把模型输出特征的多样程度拓展到了全新的范围，在数字时尚和服饰生成这个垂直领域，这种特性催生了很多突破性的研究成果，比如 TexControl 用设计巧妙的两阶段生成流程，把粗略的线条草图高效转成了表面纹理分辨率极高的 2D 服装全彩渲染图，大幅提高了织物表面的细节密度^[12]；DiffFashion 则在 2D 服饰的结构感知方向获得了突破，做到了在严格保留衣服原有廓形和局部细节的基础上完成外观属性传输^[13]。

1.2.3 国内外研究现状分析

针对服装单品的纹理替换任务，现在主流的实现方式主要分成“3D 重建”和“2D 生成重绘”两个大方向，而且慢慢向结合几何先验的 2D 重绘方向靠拢^[14]。

3D 重建技术依靠它捕捉复杂几何依赖关系的出色能力，在工业领域用得很多，这类方法通过复杂的网格重建流程做到高保真 UV 映射和织物畸变模拟^[15]，可以很好地保

留褶皱结构和阴影变化，不过，重建流程本身计算起来太复杂，还需要多视角数据才能做，这就成了实时应用和大规模推广的主要阻碍^[16]。

另一个方向是直接神经网络从输入图像里建立纹理对应关系（比如 UV 映射），避开繁琐重建过程里容易出现的拓扑错误^[17-18]。虽然自监督 3D 法线预测这类技术提高了物理合理性，但直接映射的方法处理纹理边界和角度特征关系的时候还是不够好，容易在边缘位置出现视觉伪影^[19-21]。

现在的前沿研究已经慢慢从传统建模转向深度生成式重绘模型了。利用扩散模型强大的去噪生成能力，再结合语义分割（SAM）和辅助空间约束，已经成了做到工业级高保真纹理迁移的主流研究方向，国内外研究者都在努力通过多模态控制机制，进一步提高模型在极端视角变化或是超高分辨率纹理下的表现精度。

1.2.4 存在的问题与演进趋势

尽管目前的技术在图像质量方面已经有很大进步，但服饰纹理替换这个方向还存在很多需要解决的问题，第一，结构保真度的稳定性问题很突出，现有的生成方法在替换大跨度纹理的时候，经常没办法精准抓住原始服饰的空间依赖关系，最后导致几何结构比如衣领、袖口褶皱发生扭曲或者直接丢失。第二，纹理扩展会有明显的接缝和伪影问题，过去用的平铺方法一般都会在边界地方出现很明显的割裂痕迹，还有，碰到细节差异极大的材料时，现在的重绘方法没办法很好地自适应调整。

未来的研究方向会偏向搭建自适应能力更强的端到端重绘系统^[22]。引入更深层的几何先验比如高精度深度图、法线贴图，还有多模态控制机制 ControlNet、IP-Adapter，做到对生成过程进行更精细的调整，另一方面，跟着 Web 生态和 AI 技术的融合发展，搭建依托无缝平铺策略和现代全栈开发模式的实时交互系统，是技术落地的必然发展方向^[23-24]。

1.3 研究内容

本文把生成式人工智能在时尚工业里的应用当作核心研究方向，研究内容覆盖了从底层算法创新到上层应用系统开发的完整全链路过程，第一，针对服饰纹理替换过程里，经常会出现的几何结构丢失问题，本文拿出了一种结合语义分割和多模态空间约束的智能重绘算法，用 SAM 模型做到像素级的服饰区域提取，还把 ControlNet 技术集成进去，加入了边缘检测和深度估计的双重引导，这样就能在像素生成过程里，强制把原始单品的褶皱和立体结构保留下来，在此之上，为了处理纹理大面积平铺时出现的视觉接缝伪影，本文深入探究了四方连续性生成策略还有边界感知再生算法，再搭配参数化调制机

制，做到了对纹理密度、旋转方向还有材质融合效果的精准控制。本文搭建了一套基于 Next.js 全栈框架和 ComfyUI 推理引擎的智能 Web 平台，做到了从高清预处理、扩散重绘再到历史记录管理的完整闭环工作流程。本文一共分成五个章节，各章节的安排和内容逻辑如下。

第一章为绪论。本章主要介绍本文的研究背景和实际意义，整理归纳了国内外关于传统图像处理、生成对抗网络以及扩散模型在服饰数字化方向的现有研究情况，分析现在纹理替换技术在保留结构、处理边缘等问题上遇到的主要难题，之后引出本文的核心研究内容和整体框架安排。

第二章为服饰纹理替换的需求分析与功能设计。本章围绕服装面料设计和电商展示里碰到的实际问题，利用标准用例理论仔细拆解了前端普通用户还有后台管理员的核心需求。基于这个分析，完成了系统整体功能流程的设计（包括素材构建、参数编辑、结果管理和高可用合规审计），还整理说明了支撑整个业务闭环的，包含用户行为和历史数据在内的数据库 ER 建模方案。

第三章为服饰纹理替换的智能重绘方法原理与实验分析。本章详细讲了 iRetexturing 算法框架的各个设计细节，包括基于 SAM 模型提取高清掩码，用来消除平铺伪影的四方连续纹理扩展方案，还有结合了 ControlNet（Canny 与 Depth）双重空间约束的扩散重绘机制^[14]。同时，围绕专业时尚数据集搭建了测试环境，进行了详细的对比实验和消融研究，在 LPIPS、SSIM 这些量化指标上验证了这个算法的明显优势。

第四章为服饰纹理替换智能重绘系统的工程设计与实现。本章围绕全栈架构方案的技术落地展开，讲了以 Next.js 为核心的混合渲染体系以及现代化的组件交互设计；梳理清楚了依托 Zustand 做状态调度、Prisma 做数据持久化层加上后端轻量化微服务的配合逻辑，还重点分析了整合 ComfyUI 推理引擎、WebSocket 实时状态流的开发实现过程，完整展示出这套工程体系在高并发和复杂负载情况下的可用性。

第五章为总结与展望。本章完整总结了本文在端到端系统架构、多模态空间约束算法以及智能化语义重绘的核心价值和所做的工作^[22]。同时，结合实际工程的现有条件，客观分析了当前平台在低频纹理泛化、平展服饰深度推演和复杂拓扑形变这些方面存在的不足，还对未来管线优化相关技术的发展做出了合理展望^[23-24]。

2 服饰纹理替换的需求分析与功能设计

本章主要针对目标用户群体（服装设计师、电商商家及系统管理员）在实际工作场景中的痛点进行深入分析，从而确立本系统的核心需求，并基于此设计具体的功能模块与技术实现方案。

2.1 需求分析

2.1.1 系统需求分析

在进行系统需求分析时，根据目标使用人群与业务场景的差异，本系统在功能边界上被划分为两大核心子系统：面向普通使用者的“用户模块”与面向平台维护者的“管理员模块”。基于标准的用例（Use Case）分析方法，确立了如下需求体系：

1）用户模块需求分析。普通用户是系统生图功能的核心参与者（Actor），其主要业务需求围绕账号操作、图像生成 workflow 以及历史数据的管理展开。如图 2-1 所示，第一，在执行核心的图像生成（重绘）工作流时，系统必须允许用户完成一系列必要的前置子动作，包括：上传或选择作为底图的服饰图片（Fashion Image）、导入目标纹理图片（Texture Image）、配置对应的服饰替换类型（如服装、包具、鞋靴等）以及输入生成相关的文本提示词（Prompt）；第三，系统需配套生图历史管理功能，允许用户随时浏览既往生成的图片结果，并查看和追溯对应时刻所用的特定生成参数。




图 2-1 用户模块用例图

2）管理员模块需求分析。管理员除了需要基础的安全登录凭证外，其核心需求聚焦于对系统运行资源及全局数据的统筹调度。如图 2-2 所示，管理模块的用例主要包

含三大版块：首先是“系统级用户管理”，管理员需要能够查看全平台的注册用户列表，并执行权限分配与违规账号封禁；其次是“预设资源统筹”，为了支持用户端的无门槛创作，管理员必须能通过后台上传与发布官方的预设图片库，并能删除过期或是涉嫌违规的素材资源；最后是“全局历史监控”，赋予管理员调阅全平台各个账号生成日志的权限，从而保障整个系统的生成行为在合规且安全的框架内运行。




图 2-2 管理员模块用例图

2.1.2 用户需求分析

在服装设计还有电商展示的实际业务流程里，用户对纹理替换系统的需求不单单停留在“生成”这一层，更深层面还牵扯到计算成本、工作流程效率，还有生成质量能不能控制。

1) 硬件门槛与响应速度。传统深度学习图形工作站价格很贵，多数独立设计师或是学生群体，更习惯用带消费级显卡的笔记本电脑做移动办公，所以，系统得能在有限算力下正常用，具体要求就是像 RTX 3060 Laptop (6G 显存) 这类主流的消费级配置上，就能流畅运行。同时，为了不让设计思路断开，用户对算法的反应速度要求很高，系统需要做轻量化的工作流程，做到快速出效果预览，避免因等太久推理，把设计思路打断了。

2) 纹理设计与编辑。工业级服装面料设计对纹理连续性有严格要求，设计师处理大面积布料的时候，必须要求纹理满足“四方连续”的性质，保证布料平铺延伸的时候能做到无缝衔接，不然就没法用到实际生产里。生成式 AI 本身带有随机性，设计师通常没办法只生成一次就拿到想要的完美结果，这就要求系统得给出足够精细的编辑功能，允许用户自己调整纹理图案的缩放比例、数量分布还有旋转角度，以此做到对最终视觉效果精准把控。

3) 素材管理与作业效率。要找到合适的纹理素材往往要花很多时间精力，这会直接影响整个设计的进度，用户不光需要系统给出高质量的预设素材库来激发创作灵感，

还需要能支持上传自己私藏素材的灵活功能。对电商商家这类有高频使用需求的用户来说，单张处理的模式效率太低，系统得赶紧加上纹理大批量导出的功能，还得保留完整的历史生成记录，方便用户回头查找。

4) 系统管理与安全合规。当使用系统的人数越来越多，系统得有完整的后台管理机制才行。管理员得有一个能管所有事情的工作台，不光要做到对用户账号从创建到停用的全流程管理（增删改查），更重要的是要能对用户生成出来的内容做合规检查，系统得把用户的生成参数、过往的每一步操作都记清楚，方便管理员做核查，提前挡住违规内容，保证平台用着安全，也符合合规要求。

2.2 系统设计

2.2.1 功能设计

围绕上文提出的需求框架，这套系统的功能设计目标是搭出完整数据闭环和纹理重绘的业务流程。就像图 2-3 画的，整个功能架构分成了用户端的“创作生产链路”和管理端的“安全运维链路”两个部分，区分得很清楚。

在用户功能模块里，业务流程从门户主页和身份验证开始，这里给出核心功能引导和安全准入规则，通过验证后，用户就能进入“素材构建与参数化编辑”这一主要环节，这个环节不光能灵活上传本地的多模态素材，也就是服饰原图和纹理图，还能让用户直接调取管理端下发的高质量预设图库。在此之上，用户可以用控制面板完成空间约束分配、纹理仿射变换，包括缩放、旋转操作，还有对提示词做精细化定义。

之后，提交的任务会被传到底层算法推理和实时反馈模块，系统在后端引擎运行大模型生成计算的过程里，会给前端推送当前的渲染进度，缓解用户等待的焦虑感。生成结束后，结果会进入“视觉评估与结果持久化管理”环节，靠着无损缩放的高清预览功能和原图对比工具，用户可以把满意的结果保存下来，也能批量导出。

同时，用户所有操作参数和生成的成果，都会通过“创作轨迹与数据自动归档”这条路径，直接传到管理端的“历史记录归档与合规性审计”数据池里，在管理员功能模块，管理员依靠“全局仪表盘与运行负荷统筹”工具，对系统整体算力和调用频率做整体监控；还会通过“用户账户全生命周期管理”做权限划分，同时负责把筛选好的预设素材资源包分发到前端，方便用户调取。到最后，靠着详细的归档日志，系统就形成了一套严格的合规审查机制，避免违规内容扩散，做到了从前端自由创作到后台严格监管的系统平衡和完整功能闭环。




图 2-3 功能设计流程图

2.2.2 数据库设计

本系统的数据库设计严格贴合“智能重绘与合规管理”业务流程，主要围绕“用户（User）”和“历史记录（History）”这两个核心业务实体展开设计。如图 2-4 所示，系统整体数据架构采用关系型模型，在 User 和 History 之间建立了标准的一对多（1:N）关联关系，也就是说，一个注册用户可以生成多条重绘历史记录，还能在自己的存储空间里归档这些内容，而每一条历史记录都会通过外键绑定到唯一的创建者身上，这样就能在底层结构上保证用户数据的隔离性，也让操作轨迹可以被追溯。




图 2-4 整体数据库 ER 图

针对系统底层的身份验证和权限隔离机制，核心用户表（User）的实体关系如图 2-5 所示，该表把 id 设为主键（Primary Key），包含用来做唯一登录凭证的邮箱（email）、经过 bcrypt 哈希强加密处理的密码（password），还有用户昵称（name）。另外，表结构里加了枚举类型的身份标识（role），用来更细致地区分普通用户（USER）和系统管理员

(ADMIN)，还搭配了 `createdAt` 和 `updatedAt` 两个字段，能够对账户整个生命周期做状态监控，也能留下时间戳记录。




图 2-5 用户数据库 ER 图

为了支撑系统架构里“参数化编辑”和“数据自动归档”这两个核心功能，历史记录表（History）被设计成了高度参数化的宽表结构，实体关系如图 2-6 所示。这个实体同样把 `id` 当作主键，还通过外键 `userId`（Foreign Key）直接映射到用户表，确定了生成行为的溯源源头。该表完整记录了算法工作流程里单次重绘任务的全部上下文信息，覆盖了多模态输入特征（比如纹理路径 `textureImage`、服饰底图路径 `fashionImage` 还有对应的标识名）、空间和提示词控制参数（服饰类型 `fashionType`、文本提示词 `prompt`、底层推理随机种子 `seed`），还有最终生成图像的存储路径（`imagePath`）。这种把全部参数都保存下来的设计，不光能让用户无损复现、重新编辑自己之前的创作思路，还给后台管理员做合规性审计提供了详细、没法篡改的底层数据支撑。




图 2-6 历史记录数据库 ER 图

3 服饰纹理替换的智能重绘方法原理

这一章围绕服饰纹理替换任务里的核心技术问题展开讨论，这个任务不光要求模型能完成表面纹理的迁移和生成，还要求模型在重新绘制的过程中，尽可能把服饰原本的轮廓、褶皱、阴影还有空间层次这些几何信息都保留下来。因为服饰图像本身同时有纹理细节多、结构约束明显和局部编辑需求强这些特点，只靠传统的图像编辑方法或者通用生成模型，经常没法同时兼顾纹理自然性和结构一致性，所以，很有必要搭建一套专门面向这个任务的智能重绘方法，把输入图像、纹理材料还有空间约束信息放到一起做协同建模。顺着这个思路，下文就会从算法原理开始，介绍本文提出的 iRetexturing 方法还有它的关键处理流程。

3.1 算法原理

3.1.1 算法概述

本文研究的是服饰单品图像的纹理重绘（Retexturing），主要要求就是在替换表面纹理的同时，完整保留单品原本的几何细节。为达成这个目标，本文提出了一种智能重绘方法（iRetexturing），这个方法结合用到了超分辨率、语义分割还有图像平铺等多种技术，目的就是给后续基于扩散模型的重绘过程，生成经过优化的输入数据。

如图 3-1 所示，本文的智能重绘框架用到了扩散模型，通过三个核心计算阶段一起处理服饰图像和纹理：图像先做增强和预处理，提高输入的质量，还能得到更准确的服饰区域，之后，目标纹理会用四方连续纹理扩展策略做无缝平铺，满足大面积服饰表面的覆盖需要；处理完的服饰图像、纹理信息还有空间约束会一起输入到 SDXL（Stable Diffusion XL）模型里，在文本提示词（textual prompts）和结构引导的双重条件调节下完成局部重绘。这套机制可以有选择地修改被掩盖的服饰区域，同时让新纹理和保留下来的结构特征，在物理层面保持一致融合。




图 3-1 算法概述

3.1.2 图像增强与预处理

如图 3-1(a) 显示，服饰单品图像的预处理主要是为了提高数据质量，进而做到清晰明确的语义分割结果，为了拿到指定服饰单品的精准掩码区域，同时保证分割的精度，本文先要解决提高输入图像分辨率这个基础需求，这种质量增强非常重要，因为高清图像能保留住支持更好边界检测与语义解释的关键视觉细节。在这个分辨率细化过程里，本文用了 SDXL^[25] 重绘技术做图像超分辨率处理，这项技术成功还原了低质量输入图像里的细粒度纹理和结构元素。

在处理服饰单品的低分辨率图像时，超分辨率对质量增强是必不可少的。一开始，原始低分辨率图像 I_{low} 会被缩放到基准分辨率 res_{HD} ，再通过 $n \times n$ 个图块（chunks）分区来完成处理，默认状态下， res_{HD} 设为 1024×1024 像素，搭配 $n \times n$ 个图块，来匹配 SDXL 要求的标准尺寸，放大后的图像接着会被分成多个重叠子区域 $\{I_i\}_{i=1}^n$ ，每个子区域都保留一定的重叠率 $r_{overlap}$ 。

在超分辨率任务里，本文采用条件扩散模型来做联合降噪和块重建。每个低分辨率子区域 I_i 会作为条件输入，引导反向扩散生成对应的高分辨率输出 I'_i ，该过程的数学表述如下：

$$p_{\theta}(\mathbf{x}_{HR}|\mathbf{x}_{LR}) = \int p_{\theta}(\mathbf{x}_{HR}|\mathbf{x}_t)q(\mathbf{x}_t|\mathbf{x}_{LR})d\mathbf{x}_t \quad (3-1)$$

其中， $\mathbf{x}_{LR}$ 代表低分辨率图像块 I_i 。条件概率 $p_{\theta}(\mathbf{x}_{HR}|\mathbf{x}_t)$ 用超分辨率网络给高分辨率重建做建模，而 $q(\mathbf{x}_t|\mathbf{x}_{LR})$ 表示从 $\mathbf{x}_{LR}$ 到中间状态 $\mathbf{x}_t$ 的前向加噪过程。

生成 workflow 一共有两个阶段：（1）经前向扩散把噪声从 $\mathbf{x}_{LR}$ 逐步注入到 $\mathbf{x}_t$ ，之后（2）

经反向扩散做迭代去噪，最终从 $\mathbf{x}_t$ 还原到 $\mathbf{x}_{HR}$ 。受公式 (1) 限制，这种双阶段机制在保证和原始输入结构一致的同时，也增强了纹理细节，很好解决了传统超分辨率方法里模糊、细节丢失的老问题。

该过程最终将所有增强后的子区域 $\{I'_i\}_{i=1}^n$ 无缝聚合为统一的高清输出 I_{HD} ，其目标分辨率为 res_{HD} 。本文的算法战略性地结合了分区处理与智能拼接机制，优化了大规模图像的计算效率。条件扩散过程有效地利用低分辨率结构先验，同时补充高频细节，实现了保真的超分辨率。

增强后的 I_{HD} 通过 $\text{SAM}^{[26]}$ 方法进行语义分割，使用单品特定描述符 K_{item} ，其形式化表达为：

$$(M_{item}, I_{mask}) = \text{SAM}(I_{HD}, K_{item}) \quad (3-2)$$

从而产生两个关键输出：(1) 二值分割掩码 M_{item} ，用于精确定位目标服饰单品；(2) Alpha 通道组合图像 I_{mask} ，其中非单品区域被置空（黑色背景）。这些处理后的元素随后作为下游算法组件的主要输入。

3.1.3 四方连续纹理扩展

四方连续性（Quadripartite continuity）是图案设计还有纹理合成里一个很关键的几何约束，目标是生成出来的图案是无缝、可以平铺的，这个方法把整个设计分成四个互相关联的区域，保证图案重复的时候能去掉能看见的接缝问题。它利用对齐边界位置的纹理数值来实现一阶连续性，还能扩展到更高阶的连续性（比如二次连续性），用来匹配缩放或者变形之后的平滑过渡，这套理论框架能帮我们做出跨越不同尺度和变换的视觉连贯图案。

如图 3-1(b) 所示，本文的两阶段增强过程包括：(1) 利用局部重绘完成四方连续纹理细化，以及 (2) 围绕优化后的四方连续纹理进行自适应平铺。处理完的纹理通过几何叠加和高清服饰单品的掩码区域做到精准对齐，建立了能保留原有结构的纹理集成，这样就能支持后续的设计修改工作。

虽然已经增强了连续性，扩散合成出来的纹理还是经常会出现边界不连续的问题（图 3-1(b) 插图），表现是很明显的过渡异常。为了把这些残留的伪影解决掉，本文用到了 SDXL 的受建局部重绘技术，再搭配边缘感知算子，一步步处理好区域之间的不连续问题，同时还能保住全局纹理的一致性，还有颜色的均匀性。




图 3-2 裁剪和平铺纹理的说明

原始纹理图 $I_{texture}$ 经历了系统的基于网格的分区与重组。技术工作流包含三个阶段：(1) 由标准化纹理单元组成的 2×2 复合网格组装；(2) 提取扩展后的 $L_{square} + D_{splicing}$ 大小的正方形，其中包含策略性的重叠区域（如图 3-2 所示，灰色区域代表拼接与裁剪后的区域）；(3) 过渡区域的边界约束再生。




图 3-3 生成四方连续纹理的示意图

网格组装过程利用坐标映射 $(x, y) \rightarrow (iW, jH)$ 保持相对位置，在相邻图块之间做出无缝过渡。从图 3-3 能看出，这个方法可以生成尺寸任意大的纹理场，还能维持局部纹理的连贯性，这点刚好是后续扩散生成过程的关键要求，生成出来的 I_{merge} 既当作调节输入，又作为 SDXL 去噪操作的结构先验，成功把零散的纹理样本连起来，做成连续的材质合成。

要给平铺纹理 I_{merge} 和目标服饰单品 I_{HD} 建立空间对应关系，本文做了分辨率匹配操作，用公式来表达就是：

$$T_{processed} = \Psi_{crop}(\Phi_{scale}(I_{merge}, \text{res}_{HD}), \text{res}_{HD}) \quad (3-3)$$

其中, Φ_{scale} 负责做自适应几何缩放, 把 I_{merge} 的最短边按比例对应到 I_{HD} 的最长维度上, 保证源纹理的覆盖范围比目标区域更大。接下来的 Ψ_{crop} 算子利用中心对齐的窗口采样, 提取出 res_{HD} 大小的区域, 这样就做到了纹理和服饰单品输入之间的维度对齐, 这次预处理有两个技术好处: 一是能生成适配扩散操作的几何兼容特征空间, 二是能保住对高频细节传输很重要的纹理分辨率。

该方法随后执行 Alpha 通道合成:

$$I_{overlay} = \Omega_{mask}(I_{HD}, T_{processed}, I_{mask}) \quad (3-4)$$

在这里, Ω_{mask} 会完成掩码引导的通道层级合成, 生成一份混合输入, 同时把服饰单品的几何形状还有纹理细节都做编码处理。这类复合特征图能给 SDXL 的潜在空间调节给出结构化的初始设置, 进而能在后续扩散迭代过程中达成稳定的纹理传输效果。

3.1.4 受几何约束引导的扩散重绘

为了生成有照片级真实感纹理、还能保持几何保真度的时尚单品图像, 本文用了 ControlNet^[27] 来处理纹理合成的过程, 就像图 3-1(c) 显示的那样, 这个方法要处理两个关键输入: 服饰单品的掩码图像 I_{mask} 和原始图像 I_{real} 。整个流程先对 I_{mask} 做 Canny 边缘检测, 提取出结构引导, 生成边缘特征图 C_{real} , 同时从 I_{real} 做深度预测, 导出空间约束, 得到深度图 D_{real} , 这两种互补的特征表示之后会被输入到专门的 ControlNet 分支里, 做条件合成。

这个架构在不同的 ControlNet 模块之间做到了权重专用化: 边缘处理分支靠调整参数 w_{Canny} 来优化, 做到保留轮廓, 深度分析分支则用 w_{depth} 做校准, 保持三维的一致性。这种双分支调节的方式, 让扩散模型可以在保留原始单品结构完整的同时, 完成空间连贯的重绘, 最终借助几何约束合成做到高保真重绘。

在基于 SDXL 的重绘阶段, 原始纹理 $I_{texture}$ 通过 CLIP Interrogator 处理, 用来生成描述纹理特征的提示词 P_{prompt} 。这些语义提示词之后会和类别关键词 K_{item} (用来指定服饰单品类型) 以及增强指令 G_{boost} (用来优化重绘强度) 结合在一起, 形成结构化的文本调节管道, 这个方法把这些文本控制和来自 ControlNet 的空间约束结合到一起, 让 SDXL 能够做几何受限的重绘。作为一种扩散架构, SDXL 在叠加图像 $I_{overlay}$ 的掩码区域 M_{item} 上做局部纹理合成, 同时靠潜在空间正则化保留非目标区域。

$$C_{text} = \tau_{CLIP}(K_{item} \oplus P_{prompt} \oplus G_{boost}) \quad (3-5)$$

$$z_{t-1} = z_t - \epsilon_{\theta}(z_t, t, c_{text}, \tau_{\text{ControlNet}}(w_{\text{Canny}}C_{real} + w_{\text{depth}}D_{real})) \quad (3-6)$$

其中, ϵ_{θ} 表示 SDXL 中的核心 U-Net 架构。模型接收时间步 t 的噪声潜在表示 z_t , 并通过 $\tau_{\text{ControlNet}}$ 接收来自文本调节 c_{text} 和 ControlNet 的空间约束增强。 w_{Canny} 和 w_{depth} 为加权系数。这一合成过程产生了重绘后的输出 $I_{repaint}$ 。

值得注意的是, VAE 自编码器固有的信息压缩特性使得掩码引导的合成变得必要: 本文策略性地利用掩码区域 M_{item} 将 $I_{repaint}$ 叠加到原始低分辨率图像 I_{low} 上, 从而在引入增强纹理细节的同时, 完整保留了背景等上下文元素。

3.2 实验设计与分析

3.2.1 实验环境

实验设置利用 NVIDIA GeForce RTX 4090 和 RTX 3060 GPU, 在 Windows 11 操作系统下配合 Python 3.10.8 和 CUDA 11.8 加速, 用于评估基线方法和本文提出的方法, 其详情见性能比较 (表 3-3)。本文的实现通过 ComfyUI^[28] 的模块化架构采用了 SDXL^[25], 通过其基于节点的计算图接口实现了系统的超参数优化。对于多模态调节, controlnet-union-sd-xl-1.0 模型^[29] 集成了 Canny 边缘检测和深度估计模块, 并采用经验优化的权重系数 ($w_{\text{Canny}} = 0.375$, $w_{\text{depth}} = 1.0$) 以平衡结构保留和空间一致性。

在纹理合成任务中, IPAdapter^[30] 通过交叉注意力调制保持了 $\alpha = 1.0$ 的语义引导强度, 而 SDXL^[25] 的去噪调度器在主合成阶段以 $\epsilon_{base} = 0.85$ 运行。所有的超分辨率和重绘操作均独占采用 SDXL^[25] 的潜在扩散框架, 以最大化计算并行度。

3.2.2 数据集准备

时尚单品的纹理提取工作, 是在来自 Fashion Product Images Dataset^[31] 的多样化图像集上完成的, 图像集包括手袋、鞋类还有服装这些不同品类。第一步, 采用 SAM^[26] 生成精确的分割掩码, 把每个时尚单品从背景里分离出来, 接下来, 算出每个掩码内部的最大内切矩形, 用来确定能提取纹理的区域, 如果矩形比 256×256 像素还小, 就把这个单品丢弃, 保证提取出来的纹理规格一致, 之后再从这些区域里随机提取 256×256 像素的纹理块, 覆盖不同种类的图案, 再做 Canny 边缘检测, 阈值设定为 100 和 200, 把纯色的纹理块过滤掉, 只留下细节足够的纹理块。

这个处理过程 (具体可以看表 3-1 和图 3-4) 借助内存优化批量完成, 最终得到了一个包含数千个纹理块的均衡纹理数据集, 适合用在虚拟时尚设计的重绘场景里。




图 3-4 手提包的纹理提取过程示例

Input: Fashion item image I

```
mask = SAM_segmentation(I) // Segment the fashion item from
the image
mask = convert_to_binary(mask) // Convert mask to boolean
array
rectangle = compute_largest_inscribed_rectangle(mask)
// Find largest rectangle within the mask
cropped_image = crop(I, rectangle) // Crop image to rectangle
bounds
if (cropped_image.size < 256 × 256) then // Check if cropped
region is too small
return None
end if
// Exclude if rectangle is too small
texture_patch = random_crop(cropped_image, size=256)
if (not detect_edges(texture_patch, threshold1=100, thresh-
old2=200)) then
// Apply edge detection to check texture content
return None
end if
// Discard if no edges detected
return texture_patch
// Return the extracted texture patch
```

Output: texture_patch (256 × 256 texture patch, or None if
extraction fails)

表 3-1 时尚单品的纹理提取过程伪代码

本文的评估采用 Fashion Product Images Dataset^[31]，该数据集包含 44,000 张专业拍摄的高清服饰单品图像。选择该数据集是因为它包含丰富的高清时尚单品，非常适合纹理重绘测试。为了保证类别的多样性，本文从这个集合里筛选了 4,400 个代表性样本，涵盖了手袋、鞋类和服装等 14 个不同的服饰类别。

纹理提取工作如下：第一步，采用 SAM^[26] 生成精确的分割掩码，把每个时尚单品从背景里分离出来，接下来，算出每个掩码内部的最大内切矩形（largest inscribed rectangle），用来确定能提取纹理的区域，如果矩形尺寸比 256×256 像素还小，就把这个单品丢弃，保证提取出来的纹理规格一致。之后再从这些区域里随机提取 256×256 像素的纹理块，并通过 Canny 边缘检测（阈值设定为 100 和 200）把纯色的纹理块过滤掉，只留下细节足够的纹理，最终构建出用于实验的平衡纹理数据集。

这个处理过程（具体可以看表 3-1 和图 3-4）借助内存优化批量完成，最终得到了一个包含数千个纹理块的均衡纹理数据集，适合用在虚拟时尚设计的重绘场景里。

3.2.3 评价指标与基线方法

为了完成全面的量化验证，本文用到了计算摄影以及计算机视觉领域里三种通用的图像质量评价指标：分别是学习感知图像块相似度（LPIPS）^[32]、结构相似性指数（SSIM）^[33] 还有 Fréchet Inception 距离（FID）^[34]。

1）LPIPS^[32]。利用预训练卷积神经网络里的深度特征相关性分析，来量化感知层面的相似度。跟传统的像素级对齐指标比起来，这个准则更贴合人类视觉系统实际的主观感受，可以有效判断纹理迁移过程里，高频细节特征的微观保真度有没有被破坏。

2）SSIM^[33]。借助多尺度亮度-对比度协方差分析来量化结构保存的程度。在做服饰单品的纹理替换任务时，这个参数主要用来验证生成结果在拓扑形貌、织物原有褶皱分布上，和基础素材图像的空间骨架是不是一致。

3）FID^[34]。利用计算合成分布与参考分布在深度特征空间中的 Fréchet 距离，衡量生成内容的真实感。这个统计分数数值越低，代表大规模重绘得到的成图采样集，在光影布局和材质表现上越贴近真实的商品样本，是用来衡量底层深度学习算法分布拟合能力的常用权威数据。

这些指标合起来搭建出一个多维度的评估框架，用来严格检测重绘输出结果里的纹理还原准确度、几何-结构的一致性，还有照片级的真实感。

本文在纹理迁移和虚拟试穿领域，跟六种当前最先进的方法做了全方位对比。本文的分类里，把风格迁移（style transfer）归为纹理迁移的一个子类，因为这两类方法都需要在保留结构或者语义内容的基础上，调整改变表面的外观，所以，用于纹理评估的对

比基线包括以下这些内容：

1) **Texturize**^[35]。一种围绕样例引导搭建的合成框架,利用带有基于物理渲染(PBR)材质匹配的双向块一致性优化(bidirectional patch coherence optimization),通过多尺度特征对齐做到照片级真实的纹理传播。

2) **Texture-Reformer**^[36]。这是一种形状统一的架构,结合了特定视角下的UV纹理补全,还有语义图卷积网络,利用可学习的几何先验来强制保证结构一致性。

3) **DiffFashion**^[13]。这是一个用在参考导向时尚设计里的结构感知扩散框架,它能从参考图像把服装外观转过去,同时还能保留住目标服装原本的形状和布局。这个方法专门给结构感知对应关系做了建模,这样在风格传播的过程里就能保住空间保真度。

4) **DiffuseIT**^[37]。一种围绕扩散模型的图像翻译方法,利用拆分风格和内容表示的思路完成处理。这种拆分能做到视觉属性的精准可控传递,允许在调整风格的时候不破坏原本的结构内容:这一能力尤其适配时尚领域的图像合成工作。

针对虚拟试穿任务,本次使用了这些模型:

1) **CP-VITON**^[38]。这是一种很经典的、基于图像来完成的虚拟试穿方法,它利用薄板样条(thin-plate spline)变换,加上保留纹理的外观融合,来做到几何对齐。

2) **Leffa**^[39]。Meta AI 研究人员开发的姿态感知扩散模型,利用变形场估计技术,能在做姿态操作的时候保住服装的结构完整性。

对这些方法的对比评估后,能弄清楚它们各自独特的运行机制和互相之间的联系。比如 **Texturize**^[35] 和 **Texture-Reformer**^[36] 这类靠样例驱动的方法,在还原纹理细节上表现很好,但没办法做好全局结构对齐,因为这类方法的公式设计没把几何变化考虑进去;而像 **CP-VITON**^[38] 和 **Leffa**^[39] 这类虚拟试穿技术,能很好地处理姿态带动的变形,但因为太看重空间重构,往往会牺牲纹理的精度。基于扩散的模型,比如 **DiffFashion**^[13] 和 **DiffuseIT**^[37],平衡了纹理和空间优化,把前面几类方法的优点都结合进来,只是二者在实现方式上不一样:**DiffFashion** 看重通过最优传输做外观协调,**DiffuseIT** 则更重视风格和-content分开,来做到特征解耦。

评估协议遵循 He et al.^[14] 的方式,即使用输入图像作为具有相同纹理应用的地面真值(ground-truth)参考,而本文的测试数据集引入了关键的增强:通过提高图像分辨率和多层时尚单品组合来增强结构复杂性。这些改进解释了与先前基准相比的指标变化。

3.2.4 对比实验

表 3-2 强调了本文提出的方法在时尚重绘任务中表现出卓越的性能,在多个维度上显著提升了关键评估指标。具体而言,该方法达到了 **0.8323** 的 SSIM,反映了相比现有

方法在结构保存方面的实质性改进。此外，**0.1385** 的 LPIPS 得分突显了其杰出的感知保真度。虽然 DiffuseIT^[37] 记录了较低的 FID（54.96，相比之下本文为 75.25），这归因于其强调全局特征对齐的风格迁移方法；然而，本文的方法在细粒度纹理替换方面表现优异。它以显著更低的 LPIPS（0.1385 对比 0.1618）和更高的 SSIM（0.8323 对比 0.8074）超越了 DiffuseIT^[37]，突显了其在感知相似度与结构连贯性方面的优越平衡。这些发现证实了本文的框架生成结构一致且视觉逼真的重绘时尚单品的稳健能力，确立了其在高保真应用中的优势。

Method	LPIPS	SSIM	FID
Texturize ^[35]	0.5847	0.1204	277.5
Texture-Reformer ^[36]	0.6161	0.3792	274.9
CP-VTON ^[38]	0.1452	0.8043	97.91
Leffa ^[39]	0.2383	0.7432	99.42
DiffFashion ^[13]	0.3034	0.5690	260.8
DiffuseIT ^[37]	0.1618	0.8074	54.96
Our method	0.1385	0.8323	75.25

表 3-2 不同方法的对比结果

本文的扩展实验分析表明，本框架通过准确渲染精细纹理细节并无缝适应光照和材质属性的变化，稳健地解决了广泛的时尚单品和成像条件问题。如图 3-5 所示，并在多样化的网络来源图像集上得到进一步验证，本文的方法在再现复杂纹理方面表现出色，例如围巾上明显的波浪图案、背包上清晰的花卉设计以及靴子上逼真的皮革饰面，同时有效地缓解了竞争基线中观察到的缺陷。




图 3-5 通过不同基线方法对时尚单品进行重绘的对比实验结果

具体而言，在图 3-5 中：

1) 围巾（第一行）。显示本文的方法（第 9 列）将蓝色波浪图案与卓越的自然阴影和织物褶皱对齐相结合；不像 Texturize^[35]（第 3 列）那样均匀应用图案但缺乏深度，导致结构变形和色度偏移；也不像 DiffFashion^[13]（第 7 列）那样虽然提高了色彩鲜艳度但引入了光照引起的不一致性。

2) 背包（第二行）。本文的方法（第 9 列）在花卉纹理上实现了完美的图案对齐和鲜艳的色彩；与 CP-VITON^[38]（第 5 列）形成对比，后者显示出肩带周围的轻微错位和明显的纹理细节侵蚀；以及 DiffuseIT^[37]（第 8 列），尽管经过改进，但过度平滑了复杂的图案，剥离了必要的精细细节。

3) 靴子（第三行）。本文的方法（第 9 列）生成了带有逼真磨损和光照效果的真实皮革纹理，效果超过了 Texture-Reformer^[36]（第 4 列）和 Leffa^[39]（第 6 列）。前者会出现明显的边缘退化问题，生成的过渡也更平滑、细节更少；后者生成的纹理过度简化、偏平坦，缺少材质该有的真实感。

跟这些方法比起来，本文的方法借助高精度语义分割掩码，不光能在动态光照条件下保留全局结构和局部纹理的真实度，还能给出跟每个时尚单品本身材质属性高度匹配的连贯渲染结果。这次细致的对比评估，也凸显出本文方法在达成出色纹理精度、结构完整性，还有适配不同实验场景性能方面的明显优势。



图 3-6 更多生成结果展示

图 3-6 展示了本文方法在多种时尚单品纹理重绘任务里的稳定性能。不管是复杂的图案设计，还是很细微的材质差别，本文的方法都能顺利把指定纹理无缝融合到目标单品里，还能保留单品原本的几何结构和视觉一致性，这些结果进一步证明了本文框架在

处理各种服饰类别和不同纹理复杂度时的适应能力，也体现出它在实际应用里的潜力。

另外，本文的方法支持通过图块维度编辑做到动态纹理缩放，图 3-12 展示了使用多尺度棋盘格输入的能力，重绘后的输出保留了精准的密度，纹理密度和源纹理也保持一致，这种贴合感知尺度的合成机制，保证了不同空间分辨率下的几何还原度，这点不管对复刻粗印花还是精致刺绣纹理都很关键。本文的框架可以对纹理方向和缩放操作进行稳定的参数控制，在任意角度变化 (0° – 270°) 下都能保持几何和感知层面的一致性，还支持 n 倍放大，同时保留纹理保真度，也给未来带实时可调参数的交互式编辑系统打下了不错的基础。

为了能公平评估算法的时间效率，本文在 RTX3060 设备上对多种基线方法做了基准测试。从表格 3-3 能看到，为了在不同图像分辨率之间做公平比较，本文引入了像素/图像 (MP) 和时间/百万像素 (s/MP) 作为标准化的衡量指标。

Method	Time/100 images (s)	Resolution	Pixels/image (MP)	Time/million pixels (s/MP)	Hardware
Texturize ^[35]	18.93	300×400	0.12	1.58	RTX3060
CP-VTON ^[38]	30.66	192×256	0.049	6.26	RTX3060
Texture-Reformer ^[36]	69.05	448×600	0.269	2.57	RTX3060
DiffuseIT ^[37]	2539.99	192×256	0.049	518.37	RTX3060
Leffa ^[39]	2335.17	900×1000	0.9	25.95	RTX4090
DiffFashion ^[13]	4412.74	256×256	0.065	672.0	RTX3060
Ours (RTX4090)	3494.30	768×1024	0.786	44.43	RTX4090
Ours (RTX3060)	12,885.30	768×1024	0.786	163.75	RTX3060

表 3-3 不同硬件下的图片处理过程的对比

本文的方法显示出了实际部署的出色潜力，可以在不同硬件环境下高效处理高分辨率图像 (768×1024 , 0.786 MP)。

1) 在 RTX 3060 上，该方法处理 100 张图像的批处理任务耗时 12,885 秒 (**163.75 s/MP**)，能够适配资源有限的场景，比如小型工作室或者普通实验室。

2) 在 RTX 4090 上，该方法的处理速度更快，只需要 3494 秒 (**44.43 s/MP**)，可以支撑时尚设计或者游戏领域里实时图像生成这类高性能应用需求。

跟基线方法比起来，本文提出的方法表现更好：Leffa^[39] 在 RTX3060 上没法跑起来，就算在 RTX4090 上运行，也要花 25.95 s/MP；而 Texturize^[35]、CP-VITON^[38] 和 Texture-Reformer^[36] 这类低分辨率方法，虽说跑起来速度快，却达不到高质量任务的要求。有些基线本身效率就低，像 DiffuseIT^[37] 要 518.37 s/MP、DiffFashion^[13] 要 672.0 s/MP，这更能看出本文方法在分辨率、运行效率还有硬件适配性上，做得很不错。

计算分析（Computational profiling）提到，有机会提高运行时的效率，深度估计模块占了总运行时间的 9.4%、没改动过的 SDXL 模型占 35%、CLIP 反演过程占 13%，这三个是最主要的运行瓶颈。

3.2.5 消融实验

本文做的消融研究显示，关键的参数配置和架构选择，对最终的生成质量起到了决定性作用。本次提到的方法，它的辅助处理流程结合了 Canny 边缘检测以及单目深度估计，把这两者当成 ControlNet^[27] 调节用的双重预处理模块，Canny 算子靠保留轮廓的保真度，来提高纹理对齐的精度，深度预测则是靠维持它和原始时尚单品几何形状的 3D 结构一致，来保证空间上的连贯性，这种搭配起来的预处理组合，给后面生成环节的保真度，打下了起到关键支配作用的基础约束。



图 3-7 线稿边缘检测算法评估



图 3-8 深度估计算法评估

本文的系统性评估揭示了边缘检测算法与最终合成质量之间的关键依赖关系。图 3-7 比较了四种 Canny 变体: Manga Lineart^[40]、Lineart^[41]、TEED^[42] 和 CannyEdge^[43], 分析了它们在标准化实验条件下的纹理处理能力。消融研究在代表性纹理补丁上采用了 Depth Anything V2^[44] 的优化参数, 并将所有配置中的 ControlNet 引导权重固定为 0.675。对于几何简单的纹理, Manga Lineart 和 Lineart 实现了优越的边缘保留, 而复杂图案则揭示了 Lineart^[41] 在细节保存方面的主导地位。这些发现确立了 Lineart^[41] 为本文工作流的最佳通用 Canny 实现, 平衡了不同时尚单品纹理间的结构连贯性与纹理保真度。

图 3-8 系统地基准测试了三种著名的深度估计架构: Depth Anything V2^[44]、Zoe Depth^[45] 和 Depth Anything^[46]。实验结果表明, Depth Anything V2^[44] 实现了卓越的表面细节重建保真度, 为时尚单品生成了空间连贯的纹理表示。这种优势源于其混合架构, 结合了多尺度特征融合与自适应边缘加权。Depth Anything V2 展示了跨域适应性, 在几何简单和图案密集的纹理上均保持了稳健的性能。基于这些观察, 本文采用 Lineart 进行边缘感知纹理对齐, 并采用 Depth Anything V2 进行空间一致性控制, 作为最佳算法配对, 为大多数时尚单品重绘场景提供了计算效率与重建精度之间的最佳平衡。

本文利用全面的参数空间分析, 系统研究了 Canny 边缘检测权重 (w_{Canny}) 和深度感知权重 (w_{depth}) 对背包纹理生成的共同影响, 结果如图 3-9 所示。结果表明, 当 w_{depth} 低于 0.25 (蓝框标注位置) 时, 生成的图像会出现很明显的边缘模糊, 这种情况在肩带扣、拉链轨道这类功能性结构上尤其突出, 还会伴随出现几何畸变。反过来讲, 当 w_{Canny} 超过 0.50 (绿框标注位置) 时, 纹理的语义特征会出现退化, 具体表现是出现破碎网格图案和错位条纹。




图 3-9 参数敏感性分析

根据经验，参数范围（ $w_{Canny} = 0.25-0.50$ 且 $w_{depth} = 0.75-1.00$ ，由红框标示）在边缘约束和纹理保真度之间达到了最好的平衡。跟红框插图展示的结果一样，这个范围能生成带有精确拉链细节、纹理图案一致的高质量结果，也能保证关键边界对齐准确，还能让纹理自然适配复杂表面，这些结论为优化多模态控制的纹理生成算法给出了必要的指导方向。




图 3-10 纹理细节对重绘效果的影响机制

本文利用一系列控制实验，深入研究了纹理细节影响置换效果的具体机制，如图 3-10 所示，本文检查了三组纹理对比对：(a) 织物豹纹印花对比 (b) 矢量豹纹图案，(c) 绿色皮革对比 (d) 纯绿色，以及 (e) 红色织物对比 (f) 纯红色。以皮鞋、棒球帽和背包作为标准服饰单品，SDXL 模型一共生成了 18 个可视化结果（6 个对象类别 × 3 个对比组）。

实验结果表明，带有真实材质细节（比如织物印花和皮革纹理）的纹理图像，跟没有这类细节的矢量图形或者纯色样本比起来，能生成更有 3D 感、更真实的置换效果。视觉分析表明，带有物理材质特征的纹理 (a, c, e) 在表面光场连续性（皮鞋鞋面的反射区域这一点尤其明显）和纹理边界清晰度（尤其是帽檐接缝位置）这两方面，都比对应的对照组 (b, d, f) 表现更好。

本文猜测这个现象可能和 CLIP Interrogator 的材质语义推理机制，以及 SDXL 模型预训练数据分布本身的特性有关。具体来说，真实纹理图像里存在的高频细节特征，可能更好地匹配 CLIP 文本对齐材质描述的方式，进而让扩散模型可以生成物理层面更

合理的纹理映射，这一结论为纹理引导的提示工程方法给出了关键参考方向，也提出未来研究可以通过搭建完整的面料材质词典来优化提示生成模块。




图 3-11 多角度纹理映射



图 3-12 平铺数量及缩放比例对重绘效果的影响

时尚单品重绘的一个关键但尚未被充分研究的方面在于处理多角度纹理输入，因为表面方向的变化会显著改变感知连贯性。本文通过控制纹理映射实验系统地评估了角度依赖性。如图 3-11 所示，本文的方法在 0° – 270° 的旋转范围内保持了纹理的连续性，同时通过自适应空间翘曲（adaptive spatial warping）维持纹理完整性，在不同的投影角度下实现了视觉一致的表面表达。

4 服饰纹理替换的智能重绘系统的设计与实现

4.1 系统总体设计

本系统选用基于 Next.js 的全栈开发架构。选这个架构主要是出于这几个方面的考虑：一方面，Next.js 支持服务端渲染（SSR），能明显提高系统搜索引擎优化（SEO）效果，还能加快首屏加载速度，让用户体验更好；项目用了前后端一体化的 Monorepo 架构，搭配 TypeScript 做到了前端组件和后端 API 之间共享类型，大大降低了接口对接之后的维护成本；最后，Next.js 自带的文件系统路由和内置 API Routes 简化了部署的流程，不用单独维护独立后端服务，就做到了轻量级的高效交付。

从系统各个部分的协作关系来看，本平台由前端交互层、Next.js API 接口代理层、ComfyUI 推理服务层以及 Prisma/SQLite 数据持久化层共同拼成整体，整体采用“前端统一发请求、后端集中做编排、底层做推理执行、结果返回后归档”的数据流模式。具体说起来，用户在前端界面做好素材上传、填好参数、选好工作流之后，请求会先进入到 Next.js API Routes 里，这一层负责做身份校验、参数规范化、封装工作流 JSON 还有生成任务编号；之后，后端会把整理好的标准化任务通过 HTTP 接口发送给 ComfyUI 推理服务，还会通过 WebSocket 一直监听底层的执行进度，再把状态的变化实时同步回前端界面，等图像生成完成后，后端还需要继续负责拉取结果、转发媒体代理，还要把生成参数和图像路径做持久化归档，最后把能直接访问的结果返回给用户端。走这一整套流程下来，前端不用直接和底层推理服务对接，系统在接口一致性、部署隔离性和运行安全性这几个方面，也因此得到了更稳定的保障。

在具体的技术落地中，系统后端选了 Prisma 做对象关系映射（ORM）框架，搭配 SQLite 数据库，给出了带类型安全的数据库访问接口，还有高效的数据存储方案。前端界面用 Tailwind CSS 开发，靠它原子化 CSS 的特点快速搭出响应式布局，还有现代化的视觉风格。核心框架整合了 Next.js 16 和 React 19 的最新功能，保证技术栈够新也够稳定。

数据库设计主要围绕用户（User）、生成任务（Generation）和历史记录（History）三个主要内容搭建。User 模型用来存用户的身份验证信息、角色权限（Role）还有基础资料。History 模型是系统的数据核心，会把用户每一次 AI 图像生成的操作都记录下来。在实体关联上，系统搭建了从 User 到 History 的一对多（1:N）关系，也就是一个用户可以有多条历史记录。每一条 History 记录不只是一次操作的存档，实际上它本身就是一个 Generation 实例，完整包好了这次生成的所有输入参数（比如提示词 Prompt、参考图路径）和输出结果（比如生成图路径、Seed 种子数），以此做到了可以追溯整个生成过

程的管理。

4.2 系统相关依赖和组件介绍

本系统以 Node.js 生态和现代化 Web 架构为基础搭建，为了保证重绘 workflow 能稳定运行，同时也能在高并发场景下及时给出响应，本系统把技术栈选择还有核心组件分成了下面五个功能维度：

1) 前端核心架构与语言设计。这套系统采用 Next.js 作为全栈开发的底层架构，同时结合了 React 的客户端页面显示和服务端渲染（SSR）的混合路由机制。开发语言上，整个系统的全链路都用 TypeScript 来搭建，利用它严谨的静态类型约束机制，大幅提高了前后端数据聚合接口的一致性，同时也让底层代码的稳定性更强。

2) 用户界面组件与交互体系。在视觉组件的渲染这块，系统用 Tailwind CSS 来搭建原子化的样式方案，还配合 Radix UI 给出高保真、可访问性（Accessibility）更强的底层组件基础。针对复杂影像的交互要求，系统加入了 Framer Motion 来做出流畅的空间转场动画，同时整合了 React Zoom Pan Pinch 组件，用来支持服饰原图和高分辨率纹理素材的高精度缩放查看、平移编辑操作。

3) 状态流转与数据验证机制。针对客户端这边共享数据流和异步请求的管理，系统借助 Zustand 搭配 SWR 做到了轻量级、本身带有缓存验证规则的分布式状态调度。同时，为了处理系统内的多维度表单交互，比如账号验证、提示词控制，工程底层采用了 React Hook Form 搭配 Zod 验证规则库的双轨模式，达成了基于 Schema 的强类型输入校验，这样就从客户端层面把非结构化的脏数据挡在了外面。

4) 后端微服务与数据持久化逻辑。本系统的后端节点借助 Next.js 的 API Routes 搭建轻量化微服务，数据持久化层完整集成了 Prisma ORM 框架，和高性能的 SQLite 数据库驱动引擎做了强类型绑定连接。面对比较密集的图形负载，服务端内置了 Sharp 图像库，用来做预处理环境里基准分辨率归一化，并且通过 Socket.io-client 建立反向 WebSocket 数据通道，用来监听底层扩散推理引擎的实时去噪进度，再把消息广播给前端。

5) 权限安全及系统支撑工具。针对业务场景里的身份验证与风险防控需要，该系统把 Bcrypt 高强度哈希算法，和依托 JWT 的无状态签名协议结合在了一起，搭建出了可靠的令牌安全屏障。在这套通用基础支持的前提下，系统集成了 Date-fns 来处理高并发运行时的异步时序标准化转换，同时引入 JSZip 和 File-type 两个依赖库，有效做好多个纹理项目的底层数据校验工作，还能给批量生成的样件做流式压缩分发。

4.2.1 响应式用户编辑界面

用户编辑界面是整个系统前端的核心模块，它要给用户从参数配置、提交任务到预览结果的一站式操作。这个模块采用了响应式设计的思路，保证不同尺寸的设备打开之后，都能有不错的交互使用体验。

编辑器核心的交互区域是基于 `react-hook-form` 搭建出来的，整体动态性很强。系统会根据后端传过来的 `ViewComfy` 标准化配置文件（`JSON Schema`），自动渲染出对应的参数输入控件。这些控件里包括上传参考图、纹理图用的文件选择器，调整生成细节用的文本输入框，还有控制随机种子（`Seed`）的组件。这种设计做到了界面和底层工作流解耦，要是新增或者修改工作流逻辑，不需要重新编译前端代码，只需要更新配置文件就能马上生效。

为了降低用户的使用难度，界面里加上了预设库功能（`Preset Library`）。利用 `WorkflowSwitcher` 组件，用户可以很快在不同的重绘模式（比如“全量重绘”、“局部纹理替换”这些）之间来回切换。系统自带了不少已经优化过的 `ComfyUI` 工作流模板，用户点一下就能一键加载对应的参数配置，大大简化了复杂工作流的配置步骤。

用户提交任务之后，编辑器会用 `WebSocket` 监听后端的处理进度，通过 `PreviewOutputsImageGallery` 组件实时展示生成结果。为了提高查看体验，还集成了 `React Zoom Pan Pinch` 库，支持用户对生成的高清图做无损缩放和平移查看。另外，界面还加了原图和生成图的对比功能，能帮用户直观判断重绘的效果好不好。针对移动端用户，界面用了抽屉式（`Drawer`）和折叠式布局，保证在屏幕空间有限的情况下，用户依然能流畅完成全部操作。

4.2.2 管理员后台与安全性设计

为了保证系统运行安全、数据可管控，本系统建立了完整的权限管理和审计机制，还利用服务端代理技术解决了跨域资源访问的安全问题。

系统使用基于角色的访问控制（`RBAC`）模型，在数据库的 `User` 实体里加入了 `Role` 字段，用来区分普通用户（`USER`）和管理员（`ADMIN`）。身份验证环节选择了无状态的 `JSON Web Token`（`JWT`）方案。用户登录成功之后，签发的 `Token` 载荷（`Payload`）里会嵌入角色标识。后端的 `API` 路由层靠自定义中间件拦截请求，解析 `Token` 同时校验权限，保证 `/api/admin/*` 这类敏感接口只允许管理员访问，最终在服务端做到了严格的权限隔离。

管理员工作台给出了可视化的数据管理功能。用户管理这块，支持查询、编辑和重置已注册用户的账户状态，保证系统合规使用；行为审计方面，系统完整记下了所有用

户的图像生成历史（History）。管理员能够检索、查看还有删除违规或者多余的生成记录，所有高风险操作（比如批量删除）都要经过二次确认，能有效避免误操作发生。

针对 ComfyUI 生成服务器可能出现的跨域资源共享（CORS）限制，还有混合内容（Mixed Content）安全问题，系统设计了专门的 media-proxy 服务。前端界面不会直接请求 ComfyUI 的原始图片地址，而是靠 Next.js 的 /api/media-proxy 路由转发请求。这层代理不光隐藏了后端推理服务的真实网络结构，还能充当安全屏障，保证所有媒体资源都走可信的同源通道传输，提高了系统整体的安全性和兼容性。

4.3 系统演示

本章节通过系统运行截图，直观展示本系统在低显存环境下稳定运行的各个功能模块界面。

4.3.1 系统主页与用户登录注册

系统的前端设计注重极简与现代化。图 4-1 展示了系统的初始引导主页，用户在此处可以了解系统的核心功能并快速开始体验。页面采用了响应式布局，确保在不同分辨率的屏幕下均能提供一致的视觉感官。同时，首页通过直观的卡片式设计引导用户快速定位所需服务。




图 4-1 系统初试界面

为保证系统能安全运行，用户得利用身份验证才能进入工作台，图 4-2 是登录注册窗口，支持邮箱密码登录还有新用户注册两个功能。身份验证全程按照 JWT 安全规范

执行，有效降低非法访问的风险，注册页面额外加了实时输入校验，提高了用户填写信息时的交互容错能力。




图 4-2 登录界面

4.3.2 用户工作台与各功能界面

用户登录完成后，会先进入 workflow 选择的区域，对应内容可见图 4-3，系统提前预置了好几种不同的重绘模式，能让用户根据自己需求挑选，每一种模式都做过精心调整，针对不同的使用场景和需求，给出了最合适的参数设置，能帮用户省下不少学习的功夫。用户只要跟着自己要做的任务类型，点一下对应的图标，就能加载提前设置好的算力调度方案，这种拆分模块的设计思路，不光提高了系统维护起来的方便程度，还给之后添加更多复杂的生成式任务打好了底子。




图 4-3 工作流选择界面

如果用户需要深度定制效果，系统给出了功能很强的编辑器，图 4-4 就是参数配置

面板的样子，用户能在这里调整具体的生成参数，这个面板支持对扩散步数、提示词权重还有空间约束比例做精细调整，能满足专业设计师对生成细节的高要求。而且，右侧的即时预览窗口可以在参数改完之后，快速给出反馈，让用户提前知道大致的视觉效果。

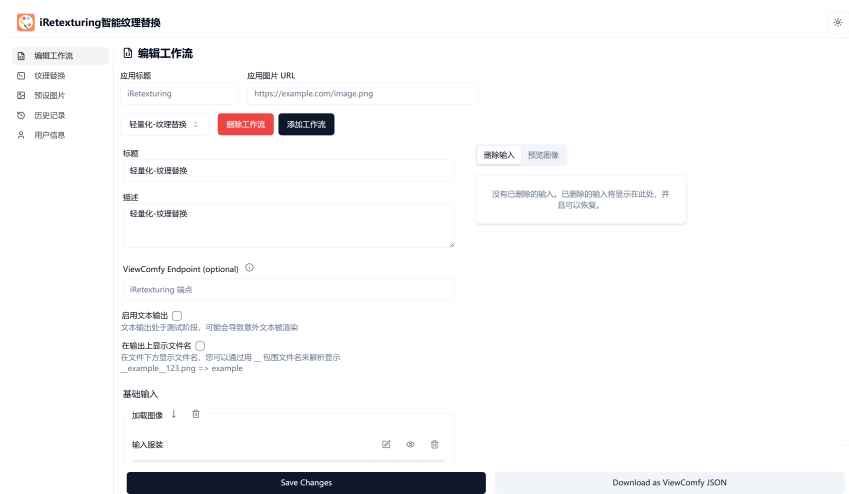


图 4-4 工作流编辑界面

针对核心的纹理迁移需求，系统设计了专门的操作视图，用拖拽式交互设计简化操作流程，图 4-5 给出了纹理替换功能的实际操作效果，能直观看出原图到生成图的变化，还给出了对比工具帮用户判断重绘质量好不好，系统会在后台实时处理图像分割和遮罩生成，用户不用有很深的图形学知识就能一键做完复杂的重绘操作。对比视图支持分区域放大，方便用户仔细看褶皱位置的纹理融合衔接够不够自然。




图 4-5 纹理替换界面

为了提高创作的效率，系统整合了预设素材管理功能，支持用户自己收藏和分类管理这些素材。就像图 4-6 里显示的那样，用户能够直接从素材库里挑出质量好的纹理素

材，这些素材都经过专业人员筛选和提前处理，能保证生成出来的效果达到最好。素材库还支持关键词搜索和快速预览，大大缩短了找合适纹理要花的时间。用户还能把自己常用的个性化纹理上传到私有素材库，做到把云端素材长期同步，还支持多设备共用。




图 4-6 预设素材库界面

系统会自动保存用户的每一次创作。图 4-7 展示了生成记录页面，用户可以随时回溯、查看和管理过往的生成任务。历史记录不仅保留了最终图像，还完整封装了生成该图像时的所有原始参数，支持一键“重用配置”以开展二次创作。这种全案存档机制为设计师提供了宝贵的灵感回溯机制和版本控制手段。




图 4-7 生成历史记录界面

图 4-8 为个人中心页面，用户在此处管理账户信息的设置。个人中心集成了账户名修改、密码重置等基础功能，并清晰展示了用户的创作时长与任务概览。未来该模块还将支持个性化主题定制，进一步提升用户的归属感与交互粘性。




图 4-8 用户信息界面

4.3.3 管理员工作台与各功能界面

管理员拥有独立的操作后台。图 4-9 展示了管理员登录后的数据概览仪表盘（Dashboard），显示了系统的关键统计指标。仪表盘通过动态图表实时监控系统的算力负载、累计生成量及活跃用户趋势，辅助管理员科学决策。关键警告信息会以高亮形式置顶展示，确保突发异常能够得到第一时间响应处理。



图 4-9 管理员仪表盘

为了维持平台的正常运转，管理员被赋予了用户管理的操作权限，这是保障平台可以稳定发展的重要规则安排，图 4-10 展示了用户管理的列表界面，支持对已经注册的用户进行信息查询以及账号状态变更，还给出了批量操作的功能，提高了整体的管理效率。后台管理系统自带多层级的过滤搜索功能，让管理员可以按照注册时间或者违规次数，快速找到特定的用户群体，同时，不管是冻结账号还是解冻账号，操作之后都会自

动生成审计记录，这样就能保证管理权限的每次使用都有记录可以查询。




图 4-10 用户管理界面

图 4-11 展示了全局生成记录管理界面，管理员可在此审计所有用户的生成内容，确保平台内容的合规性。该审计模块配合高效的图像网格展示技术，使得管理员能够在大规模语境下快速完成内容审核。若发现违规生成，管理员可立即执行下架或删除操作，从而净化系统的创作生态环境。




图 4-11 管理生成记录界面

5 总结与展望

5.1 总结

生成式人工智能现在越来越深入地用到时尚产业里，传统的图像编辑方法已经没办法满足高保真、能精准控制的服饰纹理设计要求了，本文针对服饰纹理替换时经常出现的几何结构扭曲、材质融合不自然，还有大面积平铺纹理会出现接缝伪影这些技术难题，目的是做一套既有前沿算法精度、又能满足工业使用要求的智能重绘解决方法。本文不光在底层算法这里加了多模态空间约束和特定的几何连续性引导方案，还靠着全栈工程实践把深度扩散引擎和现在常用的 Web 交互界面连在了一起，搭出了从原始图像增强、语义分割再到参数化生成管理的完整闭环。在上面这些研究的基础上，本文靠着算法和工程的深度配合，做到了对服饰重绘过程的精细化调整，它的主要作用是通过加入几何先验知识提高了扩散模型生成的可控程度，还靠着端到端的工作流让 AI 设计工具的交互效率得到优化。本文的主要工作内容可以总结成下面这些：

1) 提出了融合多模态空间约束与四方连续性生成策略的服饰纹理重绘算法。该算法利用 SAM 实现服饰区域的精准分割，结合 ControlNet 的 Canny 边缘检测和 Depth Anything V2 深度估计作为扩散生成的结构引导，并采用四方连续性纹理扩展策略提高大面积平铺时的连续性与自然度。实验结果表明，该算法在保留服饰原始几何结构和褶皱细节的同时，实现了更稳定、更真实的纹理迁移效果，其中 SSIM 达到 0.8323，LPIPS 达到 0.1385，优于传统方法。

2) 搭建了基于 Next.js 和 ComfyUI 的端到端智能重绘 Web 系统。系统以 Next.js 全栈架构为核心，整合用户交互界面、API Routes 业务接口、推理调度与历史记录管理，通过联动 ComfyUI 推理引擎实现了参数化控制、任务提交、实时进度反馈和结果归档等关键功能。最终完成的系统形成了从素材上传到结果管理的完整闭环，为 AI 辅助时尚设计场景提供了可部署、可交互、可扩展的工程化应用方案。

5.2 不足与展望

虽然这次课题提出的，围绕扩散模型做出来的服饰重绘框架，在大多数场景里都表现出很不错的性能，但受现在生成方式、底层模型本身能力的限制，这套系统还是存在一些没法回避的局限问题。

在材质纹理的微观表达这块，系统对低频细节特征的泛化能力有一定限制。要是输入的纹理材料本身就缺少逼真的高频细节，比如细小的纤维质感或者局部的反光属性，那么生成的重绘结果，往往没法给出让人信服的材质外观，也做不出明显的立体感。这

个缺陷很大程度上来自底层大模型用的 CLIP 文本对齐的材质描述方法，当处理信息熵比较低的纯色，或者简单纹理输入的时候，模型没办法凭空造出逼真渲染需要的微观细节，这就会在一定程度上降低长焦或者微距视角下，输出图像的视觉保真程度。

除了微观材质的生成限制之外，这套系统在重构平坦服饰的时候，也暴露出空间深度感知能力不够的问题。当输入的原始服饰版型比较平展，本身没有天然的光影深度，也没有层次丰富的面料褶皱的时候，当前这套重绘流程很容易让输出图像失去该有的三维立体结构和物理触感。这个问题主要是受 ControlNet 组件在空间深度特征提取上的鲁棒性瓶颈限制，要是原图没法给出足够强烈的深度线索当视觉锚点，空间结构模块就很难有效推算、重构出精准的立体外形。

复杂拓扑形变下产生的物理几何失真，是现在这类 2D 生成框架天生存在的难点。因为这套系统本质上属于建立在受控去噪机制上的视觉重绘应用，缺少计算成本很高的物理级 3D 几何重建与光线追踪（Ray Tracing）流程支撑。处理织物的剧烈折叠或者复杂遮挡时，真实的物理状态一般要求纹理跟着拓扑截面，呈现出比较剧烈的不连续映射，但现在的生成策略更倾向于输出全局平滑连续的纹理内容，不可避免会让局部区域出现物理层面的结构失真。尤其是遇到强光照或者自阴影这类极端验证条件时，这种几何细节和现实物理特征脱节的情况，会变得格外明显。

展望后续的研究，接下来的研究将会系统性地对这个方法做增强，重点方向是提高计算效率和优化处理流程，比如说开发适配自动参数调整的鲁棒协议，同时保留当前实现已经展现出的精度。就算存在上面说的这些局限性，这个框架仍然算得上是时尚单品重绘领域里的重要进展，也给后续进一步探索打下了扎实的基础。

参考文献

- [1] 陈静. 电子商务背景下增强现实技术设计特性对消费者网络购买意向影响研究[J]. 东北大学硕士学位论文, 2017.
- [2] Shen J, Sun H, Mao X, et al. Color-mood-aware clothing re-texturing[J]. Proceedings of the 2011 12th International Conference on Computer-Aided Design and Computer Graphics, 2011: 365-372.
- [3] 宛如玉, 申鸿, 郭荣辉. 数字化服装结构设计技术的研究进展[J]. 纺织科学与工程学报, 2024, 41(2): 58-65.
- [4] 陈炜, 易港. 参数化设计在服饰设计领域的应用与探索[J]. 服装学报, 2022, 7(2): 128-134.
- [5] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in Neural Information Processing Systems, 2014, 27: 2672-2680.
- [6] Yan H, Zhang H, Zhang Z. Learning to disentangle the colors, textures, and shapes of fashion items: A unified framework[J]. IEEE Transactions on Multimedia, 2023, 25: 3991-4003.
- [7] Jung J, Kim H, Park J. Deep fashion designer: Generative adversarial networks for fashion item generation based on many-to-one image translation[J]. Electronics, 2025, 14(1): 159.
- [8] Solanki A, Kang S S, Singla S, et al. High resolution fashion image generation using Quantum-GAN [J]. Proceedings of the 2024 First International Conference on Technological Innovations and Advance Computing (TIACOMP), 2024: 1-6.
- [9] Sohl-Dickstein J, Weiss E, Maheswaranathan N, et al. Deep unsupervised learning using nonequilibrium thermodynamics[J]. Proceedings of the 32nd International Conference on Machine Learning, 2015: 2256-2265.
- [10] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[J]. Advances in Neural Information Processing Systems, 2020, 33: 6840-6851.
- [11] Song Y, Ermon S. Generative modeling by estimating gradients of the data distribution[J]. Advances in Neural Information Processing Systems, 2019, 32: 11918-11930.
- [12] Zhang Y, Zhang T, Xie H. TexControl: Sketch based two-stage fashion image generation using diffusion model[J]. Proceedings of the 2024 Nicograph International (NicoInt), 2024: 64-68.
- [13] Cao S, Chai W, Hao S, et al. Diffashion: Reference-based fashion design with structure-aware transfer by diffusion models[J]. IEEE Transactions on Multimedia, 2023, 26: 3962-3975.
- [14] He W, Song B, Zhang N, et al. Modeling and realization of image-based garment texture transfer[J]. The Visual Computer, 2024, 40(9): 6063-6079.
- [15] Xie Y, Mao H, Yao A, et al. TemporalUV: Capturing loose clothing with temporally coherent UV coordinates[J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 9621-9631.

- [16] Jafarian Y, Wang T Y, Ceylan D, et al. Normal-guided garment UV prediction for human re-texturing [J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 6526-6536.
- [17] Neverova N, Novotny D, Szafraniec M, et al. Continuous surface embeddings[J]. Advances in Neural Information Processing Systems, 2020, 33: 17237-17247.
- [18] Neverova N, Sanakoyeu A, Labatut P, et al. Discovering relationships between object categories via universal canonical maps[J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 9074-9083.
- [19] 谭泽霖, 白静, 陈冉, 等. FP-VTON: 基于注意力机制的特征保持虚拟试衣网络[J]. 计算机工程与应用, 2022, 58(23): 186-196.
- [20] 侯珏, 丁焕, 杨阳, 等. 基于混合知识蒸馏和特征增强技术的轻量级无解析式虚拟试衣网络[J]. 纺织学报, 2024, 45(9): 164-174.
- [21] 刘玉叶, 王萍. 基于纹理特征学习的高精度虚拟试穿智能算法[J]. 纺织学报, 2023, 44(5): 177-183.
- [22] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30: 6000-6010.
- [23] Aigerman N, Groueix T. Generative Escher meshes[J]. ACM SIGGRAPH 2024 Conference Papers, 2024: 1-11.
- [24] Rodriguez-Pardo C, Garces E. SeamlessGAN: Self-supervised synthesis of tileable texture maps[J]. IEEE Transactions on Visualization and Computer Graphics, 2022, 28(12): 4545-4557.
- [25] Podell D, English Z, Lacey K, et al. SDXL: Improving latent diffusion models for high-resolution image synthesis[J]. Proceedings of the International Conference on Learning Representations, 2024.
- [26] Kirillov A, Mintun E, Ravi N, et al. Segment anything[J]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 4015-4026.
- [27] Zhang L, Rao A, Agrawala M. Adding conditional control to text-to-image diffusion models[J]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 3836-3847.
- [28] ComfyUI. ComfyUI: A Flexible User Interface for AI Image Generation[J]. GitHub Repository, 2025.
- [29] Face H. ControlNet-union-SDXL-1.0[J]. HuggingFace Repository, 2025.
- [30] Ye H, Zhang J, Liu S, et al. IP-adapter: Text compatible image prompt adapter for text-to-image diffusion models[J]. arXiv preprint arXiv:2308.06721, 2023.
- [31] Aggarwal P. Fashion product images dataset[J]. Kaggle, 2019.
- [32] Zhang R, Isola P, Efros A A, et al. The unreasonable effectiveness of deep features as a perceptual metric[J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018: 586-595.

- [33] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612.
- [34] Heusel M, Ramsauer H, Unterthiner T, et al. GANs trained by a two time-scale update rule converge to a local Nash equilibrium[J]. Advances in Neural Information Processing Systems, 2017, 30: 6629-6640.
- [35] Efros A A, Freeman W T. Image quilting for texture synthesis and transfer[J]. Seminal Graphics Papers: Pushing the Boundaries, Volume 2, 2023: 341-346.
- [36] Wang Z, Zhao L, Chen H, et al. Texture reformer: Towards fast and universal interactive texture transfer [J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2022, 36(3): 2623-2631.
- [37] Kwon G, Ye J C. Diffusion-based image translation using disentangled style and content representation [J]. Proceedings of the International Conference on Learning Representations, 2023.
- [38] Wang B, Zheng H, Liang X, et al. Toward characteristic-preserving image-based virtual try-on network [J]. Proceedings of the European Conference on Computer Vision (ECCV), 2018: 589-604.
- [39] Zhou Z, Liu S, Han X, et al. Learning Flow Fields in Attention for Controllable Person Image Generation[J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2025.
- [40] Xiang X, Liu D, Yang X, et al. Adversarial open domain adaptation for sketch-to-photo synthesis[J]. Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, 2022: 1344-1354.
- [41] Kang H, Lee S, Chui C K. Coherent line drawing[J]. Proceedings of the 5th International Symposium on Non-photorealistic Animation and Rendering, 2007: 43-50.
- [42] Soria X, Li Y, Rouhani M, et al. Tiny and efficient model for the edge detection generalization[J]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 1364-1373.
- [43] Canny J. A computational approach to edge detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1986, PAMI-8(6): 679-698.
- [44] Yang L, Kang B, Huang Z, et al. Depth Anything v2[J]. Advances in Neural Information Processing Systems, 2024, 37: 21875-21911.
- [45] Bhat S F, Birkl R, Wofk D, et al. ZoeDepth: Zero-shot transfer by combining relative and metric depth [J]. arXiv preprint arXiv:2302.12288, 2023.
- [46] Yang L, Kang B, Huang Z, et al. Depth Anything: Unleashing the power of large-scale unlabeled data [J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024: 10371-10381.

致谢

岁月匆匆，曲折充实的本科生活即将落下帷幕。四年的本科时光一路走来，经历颇多、感慨良多。

首先，我衷心感谢我的本科导师金耀老师。千言万语难以表达我对金老师的感激之情，老师是我本科科研道路上的引路人和指导者。若无金老师的悉心指引，我的本科科研之路将会寸步难行。由衷感谢金老师在本科科研过程中给予我的耐心指导与无私帮助。

其次，感谢各位亲朋好友以及心理咨询老师。在我情绪低落、意志动摇的时刻，是他们给予了我温暖的陪伴与心理支持。正是有了他们的鼓励与宽慰，我才能坚强面对学业与生活中遇到的种种困难。

人生路漫漫，也期许自己在未来的研究生生涯中，能够有幸再遇良师益友，继续心怀感恩、稳步前行。

张雅瑞

2026年5月10日