



基于轻量化卷积神经网络的疲劳驾驶检测

程 泽, 林富生, 靳 朝, 周鼎贺

引用本文:

程 泽, 林富生, 靳 朝, 周鼎贺. 基于轻量化卷积神经网络的疲劳驾驶检测[J]. 重庆理工大学学报 (自然科学), 2022, 36(2): 142–150.

相似文章推荐 (请使用火狐或IE浏览器查看文章)

Similar articles recommended (Please use Firefox or IE to view the article)

基于智能手表的疲劳驾驶监测方法研究

Research on Driver Fatigue Monitoring Method Based on Smart Watch

重庆理工大学学报 (自然科学). 2020, 34(12): 170–176 [https://doi.org/10.3969/j.issn.1674-8425\(z\).2020.12.022](https://doi.org/10.3969/j.issn.1674-8425(z).2020.12.022)

基于眼部特征的疲劳驾驶辨识方法研究

An Identification Method of Fatigue Driving Based on Eye Features

重庆理工大学学报 (自然科学). 2016, 30(10): 11–15,33 [https://doi.org/10.3969/j.issn.1674-8425\(z\).2016.10.002](https://doi.org/10.3969/j.issn.1674-8425(z).2016.10.002)

基于YOLOV3的改进模型在行人检测中的应用

Application of Improved Model Based on YOLOV3 in Pedestrian Detection

重庆理工大学学报 (自然科学). 2020, 34(8): 155–164 [https://doi.org/10.3969/j.issn.1674-8425\(z\).2020.08.023](https://doi.org/10.3969/j.issn.1674-8425(z).2020.08.023)

基于YOLO-GT网络的零售商品目标检测方法

Method of Retail Commodity Target Detection Based on YOLO-GT Network

重庆理工大学学报 (自然科学). 2021, 35(6): 174–184 [https://doi.org/10.3969/j.issn.1674-8425\(z\).2021.06.022](https://doi.org/10.3969/j.issn.1674-8425(z).2021.06.022)

融合跨阶段局部网络和空间金字塔池化的Yolov3目标检测算法

Yolov3 Target Detection Algorithm Based on Cross Stage Local Network and Spatial Pyramid Pooling

重庆理工大学学报 (自然科学). 2021, 35(10): 136–143 [https://doi.org/10.3969/j.issn.1674-8425\(z\).2021.10.018](https://doi.org/10.3969/j.issn.1674-8425(z).2021.10.018)



基于轻量化卷积神经网络的疲劳驾驶检测

程 泽^{1,2,3}, 林富生^{1,2,3}, 靳 朝^{1,2,3}, 周鼎贺^{1,2,3}

(1. 武汉纺织大学 机械工程与自动化学院, 武汉 430200;

2. 湖北省数字化纺织装备重点实验室, 武汉 430200;

3. 三维纺织湖北省工程研究中心, 武汉 430200)

摘 要:针对现有疲劳驾驶检测模型在判定准确性与实时性上的不平衡问题,设计了一种基于轻量化卷积神经网络 EMLite-Yolo-V4 的检测模型。通过使用 MobileNet-V2 作为目标检测网络 Yolo-V4 的主干特征提取网络,并且降低卷积通道系数 α ,使得网络参数量大幅度下降;改进柔性非极大值抑制使得目标框无需再同时考虑得分与重合度,进一步优化检测速率;加入轻量级特征金字塔 FPN-tiny 并且融合 mosaic 数据增强方法,以保证模型的检测精度。最后,利用 EMLite-Yolo-V4 提取面部疲劳特征,PERCLOS 与单位时间打哈欠次数对疲劳特征进行状态判定并输出结果。实验表明:该检测模型的准确率达到 97.39%,mAP 指标为 80.02%,单帧检测速度为 20.83 ms,模型大小仅为 9 MB,有效平衡了疲劳驾驶检测的准确性与实时性。

关 键 词:疲劳驾驶检测;轻量化卷积神经网络;轻量级特征金字塔;柔性非极大值抑制;数据增强

中图分类号:TP391.41

文献标识码:A

文章编号:1674-8425(2022)02-0142-09

近年来,由于疲劳驾驶造成的交通事故屡见不鲜。频发的交通事故给国家和个人的生命财产安全带来了严重的损失。及时检测出驾驶员的疲劳驾驶状态并做出预警已成为降低此类安全事故的有效方法之一。

疲劳驾驶状态检测技术大致可分为基于传统特征检测模式和基于深度学习检测模式 2 种^[1-5]。朱名流等^[6]通过传统 HOG 特征进行人

脸识别并使用人脸特征点模型进行人眼和嘴部的定位,根据人眼与嘴部的张开与闭合,最后根据 PERCLOS 值判断疲劳驾驶状态。该方法不依赖深层网络,可大幅度提升检测速度,但在检测精度上与深度学习网络还是有一定差距。徐莲等^[7]通过多任务级联卷积神经网络对眼部状态进行识别,最后根据 PERCLOS 判定疲劳驾驶状态。该方法虽然使用了深度学习网络去对特征进行分类处

收稿日期:2021-06-03

作者简介:程泽,男,硕士研究生,主要从事图像处理与检测研究,E-mail:531550085@qq.com;通讯作者 林富生,男,博士,教授,主要从事信号分析与故障诊断研究,E-mail:64428786@qq.com。

本文引用格式:程泽,林富生,靳朝,等.基于轻量化卷积神经网络的疲劳驾驶检测[J].重庆理工大学学报(自然科学),2022,36(2):142-150.

Citation format:CHENG Ze, LIN Fusheng, JIN Zhao, et al. Fatigue driving detection method based on lightweight convolutional neural network [J]. Journal of Chongqing University of Technology (Natural Science), 2022, 36(2): 142-150.

理,但是由于多任务级联导致网络参数过多,虽提高了检测精度但检测实时性略显不稳定。王旭彬等^[8]使用目标检测框架 Yolo-V3 对驾驶员面部定位并对其人脸特征点提取与分析,评价驾驶员状态。该方法虽然利用了深度学习网络,但该网络只作用于人脸位置检测,并没有作用于人脸特征提取,导致最终的检测结果仍旧与传统特征检测方法相当,在检测精度与实时性的平衡性上仍需加强。基于传统特征的检测模式多以特征提取与浅层网络训练模型的方式进行,该模式虽然检测速度较快,但是检测精度不稳定。基于深度学习的检测模式多以深层网络作为特征的训练网络,由于网络层数多、参数多,导致检测速度下降。由于疲劳驾驶检测对实时性要求极高,使用传统的深度学习网络进行疲劳驾驶检测缺乏实用性。

针对以上问题,本文对深层网络进行轻量化

改进,使得改进后的网络能够在尽可能少牺牲检测精度的前提下大幅度提升检测速率与实时性,同时有效提升驾驶员疲劳检测的实用性与可靠性。

1 目标检测网络 Yolo-V4 轻量化改进

1.1 Yolo-V4 网络结构

目标检测网络 Yolo-V4 结构^[9]如图 1 所示。其整个网络结构可以分为 3 个部分:首先是主干特征提取网络(backbone)模块,对应图上的 CSP-Darknet53,用来获得 3 个初步的有效特征层;其次是加强特征提取网络模块,对应图上的 SPP 和 PANet,用来对 3 个初步的有效特征层进行特征融合,提取出更好的特征;最后是预测网络模块,对应图上的 3 个尺度输出,用来获得预测结果。图中左下部分为各个组件的结构。

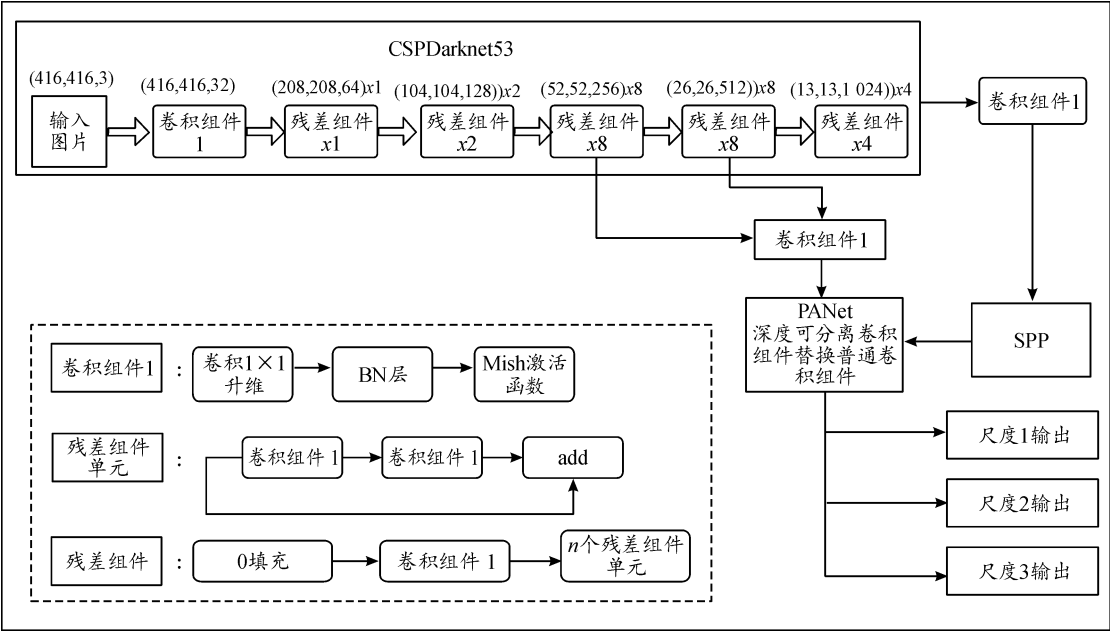


图 1 Yolo-V4 结构框图

1.2 EMLite-Yolo-V4 网络结构设计

由于 Yolo-V4 的网络参数数量较大,导致在模型训练时耗时较长,所得模型占用内存空间较大,在处理一些简单的目标检测任务时检测速度会受到

一定影响。所以针对轻量化与检测精度 2 个因素设计了一种 EMLite-Yolo-V4 超轻量级目标检测网络结构,如图 2 所示。该网络结构对 Yolo-V4 网络中 3 个部分进行了改进。

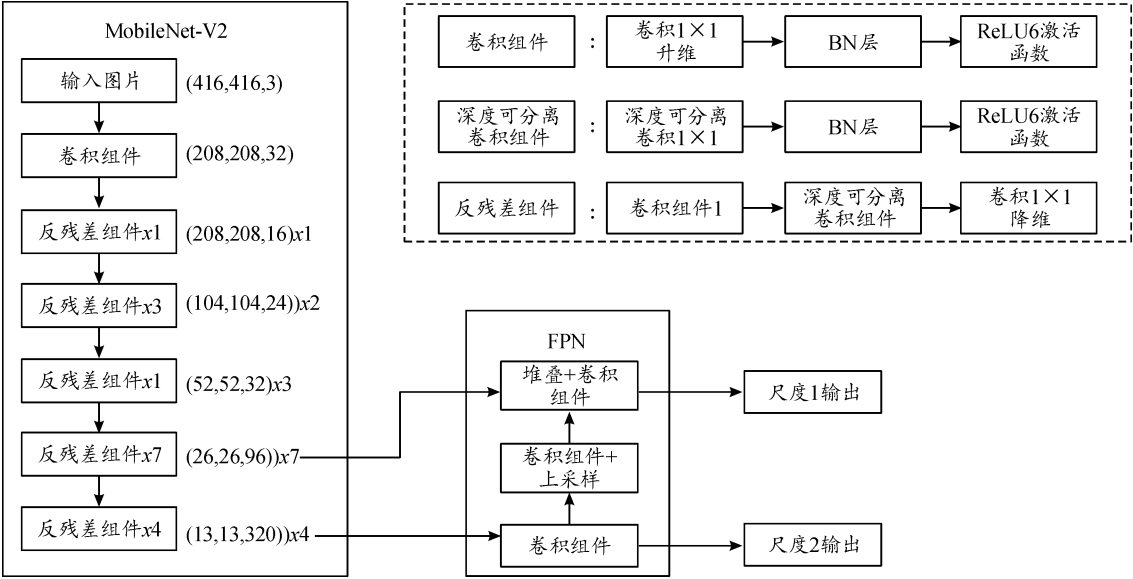


图2 EMLite-Yolo-V4 结构图

1.2.1 主干特征提取网络改进

首先,由于 Yolo-V4 的主干特征提取网络 CSPDarknek53 的参数数量较大,导致在模型训练时耗时较长,所得模型占用内存空间较大,在处理一些简单的目标检测任务时检测速度会受到一定影响。所以使用 MobileNet-V2 替换 CSPDarknek53^[10]。其中 MobileNet-V2 是一种轻量级主干特征提取网络,其网络结构如表 1 所示。其中 Input 为输入维度,Operator 为操作组件,t 为瓶颈层内部升维的倍数,c 为特征的维度,n 为该瓶颈层重复的次数,s 为瓶颈层第一个卷积的步幅。Operator 中的 bottleneck 表示线性瓶颈层,Conv2d 表示二维卷积操作,Avgpool 表示平均池化操作。

表 1 MobileNet-V2 网络结构

Input	Operator	t	c	n	s
2 242 × 3	Conv2d	—	32	1	2
1 122 × 32	bottleneck	1	16	1	1
1 122 × 16	bottleneck	6	24	2	2
562 × 24	bottleneck	6	32	3	2
282 × 32	bottleneck	6	64	4	2
282 × 64	bottleneck	6	96	3	1
142 × 96	bottleneck	6	160	3	2
72 × 160	bottleneck	6	320	1	1
72 × 320	Conv2d 1 × 1	—	1 280	1	1
72 × 1280	Avgpool 7 × 7	—	—	1	—
1 × 1 × k	Conv2d 1 × 1	—	k	—	—

MobileNet-V2 的核心是利用深度可分离卷积块(图 3)代替普通卷积块^[11-12]大幅度减少参数量,其中深度可分离卷积过程如图 4 所示。




图3 深度可分离卷积结构图




图4 深度可分离卷积过程图

其中,普通卷积计算过程如图 5 所示。假设输入图片维度为 (d_{in}, d_{in}, C) ,其中 C 为图片的通道数, (d_{in}, d_{in}) 为图片的大小,假设卷积核大小为

(d_k, d_k, C) , 共有 N 个, 执行普通卷积计算后输出大小为 (d_{out}, d_{out}, N) 。普通卷积总计算量 S_1 为:

$$S_1 = N \times d_{out}^2 \times d_k^2 \times C \quad (1)$$




图5 普通卷积计算过程

深度可分离卷积计算过程分为 2 步, 如图 6 所示。第 1 步为深度卷积, 输入图片仍为 (d_{in}, d_{in}, C) , 在深度卷积操作中卷积一次应用于单个通道, 因此卷积核大小为 $(d_k, d_k, 1)$, 共有 C 个, 则输出图片大小为 (d_{out}, d_{out}, C) ; 第 2 步为逐点卷积, 输入图片为深度卷积的输出 (d_{out}, d_{out}, C) , 在深度卷积操作中卷积一次应用于单个通道, 因此卷积核大小为 $(1, 1, C)$, 共有 N 个, 则输出图片大小为 (d_{out}, d_{out}, C) 。深度可分离卷积的总计算量 S_2 为:

$$S_2 = C \times d_{out}^2 \times (d_k^2 + N) \quad (2)$$




图6 深度可分离卷积计算过程

由上述分析计算可知, 深度可分离卷积的计算量是普通卷积计算量的 $\frac{1}{N} + \frac{1}{d_k^2}$ 倍, 所以在网络中融入深度可分离卷积可大大降低计算量, 加快检测速度。

1.2.2 加强特征提取网络改进

Yolo-V4 的加强特征提取网络 PANet、SPP 中的卷积结构比较复杂, 也导致了整个网络参数量的增加。因此, EMLite-Yolo-V4 中将 PANet、SPP

替换为一种轻量级的特征金字塔 FPN-tiny, 如图 7 所示。FPN-tiny 利用多尺度手段有效提升了小目标的检测效果, 同时由于 FPN-tiny 获得了更加鲁棒的高层语义特征, 使得模型学习过程更为高效, 进而提升模型准确率, 以弥补整体网络参数减少而带来的精度损失。

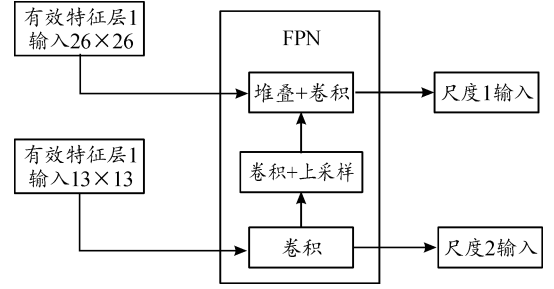


图7 FPN-tiny 结构

1.2.3 柔性非极大值抑制 (Soft-NMS) 与卷积通道参数 alpha 改进

针对本文数量较少且目标大小中等的检测目标时, 由于先验框数量固定为 3 个尺度共类聚 9 个中心点, 导致需要比较的预测框数量较多, 此时若进行柔性非极大值抑制, 每个预测框需要计算得分与重合度 2 个指标。由于待检测目标大小适中, 检测背景较为简单, 且在检测过程中被检测目标为无相对位移的目标, 不会出现被检测目标重合问题, 这样导致计算预测框重合度就为冗余操作, 检测精度并没有提升, 反而使得检测速度变慢。所以 EMLite-Yolo-V4 网络结构中将柔性非极大值抑制剔除计算预测框重合度的因素, 在不丢失检测精度的同时提高检测速度。如表 2 所示, 对同一帧图像进行眼嘴特征检测, 分别使用改进前后的柔性非极大值抑制进行实验, 结果表明, 改进后的非极大值抑制在单帧检测时间上可减少将近一半, 使得 EMLite-Yolo-V4 网络的检测速率进一步加快。

表2 柔性非极大值抑制改进对比结果

名称	待检测目标/个	单帧检测所用时间/ms
柔性非极大值抑制	4	0.633
改进后的非极大值抑制	4	0.332

为了继续缩减网络参数量, 通过修改卷积通

道 α 系数,将默认值 1 改为 0.5,使得主干提取网络与加强特征提取网络中卷积通道数减少,使得 EMLite-Yolo-V4 网络的参数量只有 9 MB。

2 模型训练与分析

2.1 数据集

YawDD(a yawning detetion dataset) 为公开的疲劳驾驶打哈欠数据集^[13]。ZJU (Zhejiang University dataset) 为浙江大学公开的人脸眨眼视频数据集^[14]。融合 2 个数据集构成一个包含具有睁眼、闭眼、张嘴、闭嘴 4 种特征的完整数据集。该数据集包含 2 组具有不同面部特征驾驶员的视频数据,且视频均是在真实和变化的驾驶状态光线条件下拍摄的。该数据集包括来自不同肤色的、戴或不戴眼镜的男女驾驶员的面部信息,根据本实验要求标注了睁眼、闭眼、张嘴、闭嘴 4 种特征。为了满足实验需求,在保证训练与验证结果一致性的前提下,对数据集进行了部分裁剪,裁剪后的新数据集包含 4 个眼嘴特征,共有 5 544 张驾驶员面部图像。表 3 给出了数据集按 8:1:1 的比例划分后的训练、验证和测试集。

表 3 YawDD-ZJU 数据集划分情况

数据集 划分	睁眼 样本	闭眼 样本	张嘴 样本	闭嘴 样本
训练集	1 144	1 162	1 025	1 105
验证集	143	145	128	138
测试集	143	145	128	138

2.2 融合离线数据增强与 Mosaic 数据增强

为了提高模型的泛化能力与鲁棒性,本文使用了 2 种数据增强方式,分别为离线数据增强和 Mosaic 数据增强。

离线数据增强包括数据翻转、数据旋转、数据缩放、数据剪裁、数据移位、增加高斯噪声和颜色增强 7 个方法。由于本文训练数据为人脸眼嘴特征,其中数据缩放、数据剪裁和数据移位会破坏特征的完整性。故只使用数据翻转、数据旋转、增加

高斯噪声和颜色增强 4 种方法来增强数据集。如图 8 所示为 4 种数据增强方法的效果。



图 8 离线数据增强方法

Mosaic 数据增强直接对 4 张图片进行随机拼接,将拼接后的新图片传入训练网络中进行特征提取。使用 Mosaic 数据增强可以大大丰富检测目标的背景,进而提升检测精度。Mosaic 数据增强方法如图 9 所示。



图 9 Mosaic 数据增强方法

2.3 模型训练结果对比

实验以主频 2.30 GHz、内存 16 G 的 Intel(r) Core(TM) i5-8300H 处理器和 Nvidia GeForce GTX 1060 GPU(6G 显存)为实验平台,采用 Tensorflow/ Keras 平台建立神经网络模型,并选择 Tensorflow 框架作为 Keras 平台的后端。训练时,采用冻结训练法和早停法(early stopping)加快训练速度。初始学习率设置为 0.000 1,学习率衰减设置为 0.000 01。输入数据维度为 416 * 416,训练总世代数(Epoch)设置为 100,冻结世代数设置为 50,一次训练所选取的样本数(Batch size)设置为 8。训练过程中的损失曲线与精度曲线如图 10、11 所示。

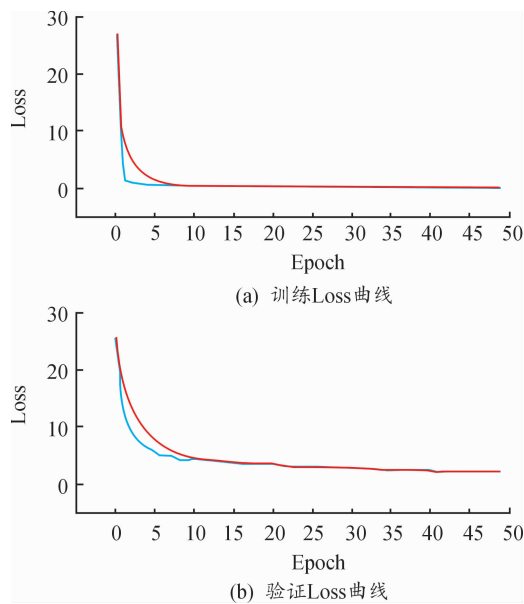


图 10 损失曲线

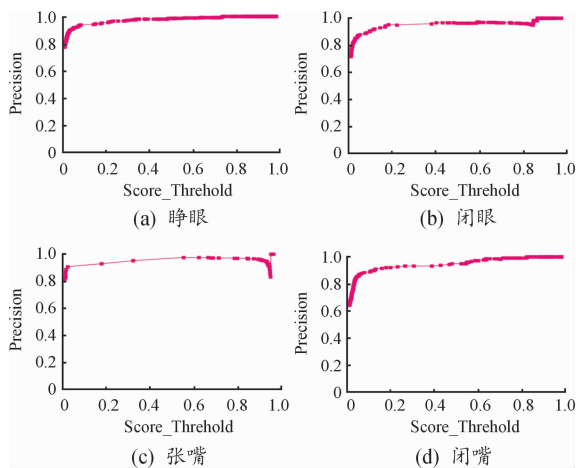


图 11 精度曲线

表 4 为 4 种眼嘴特征在 EMLite-Yolo-V4 模型下的性能数据,由表中数据可以得出模型对于 4 种眼嘴特征具有较高精度与检出率,平均分类精度达到 97.39%,平均 mAP 为 80.02%。

表 4 4 种眼嘴特征的模型性能数据

	睁眼	闭眼	张嘴	闭嘴
分类精度/%	96.12	97.67	98.21	97.54
mAP/%	78.59	80.18	79.96	81.36

由表 5 数据可得,模型针对本文改进方法均较前阶段 mAP 值有一定提升,由于检测目标为驾驶员面部眼嘴特征,通过 MobileNet-V2 作为主干

特征提取网络,融合 FPN-tiny 轻量级特征金字塔,在尽量不牺牲精度的情况下大幅度提升检测速度,使得 EMLite-Yolo-V4 模型检测效果显著提升,从而验证了本文改进方案的有效性。

表 5 EMLite-Yolo-V4 分模块对比结果

添加、改进的模块	本文 EMLite-Yolo-V4 检测模型			
MobileNet-V2	✓	✓	✓	✓
FPN-tiny		✓	✓	✓
改进 Soft-NMS			✓	✓
卷积通道参数 alpha				✓
总类别 mAP/%	73.45	76.27	79.64	80.02

对比其他 Yolo-V4 的改进方案,将本文 EMLite-Yolo-V4 与 Yolo-V4 和基于文献[15-17]网络训练好的模型做评价测试,该测试包含检测模型的预测时间、模型大小和模型平均分类精度。如表 6 所示,EMLite-Yolo-V4 网络在预测时间、模型大小、mAP 值上均优于文献[15-17]网络。EMLite-Yolo-V4 网络的精度略小于 Yolo-V4 网络,但在预测时间与模型大小上均优于 Yolo-V4。

表 6 5 种网络结构训练结果对比

模型名称	预测时间/ (帧·s ⁻¹)	模型大小/ MB	平均分类 精度/%
Yolo-V4	25	246	98.36
文献[15]	39	96	93.65
文献[16]	21	201	95.18
文献[17]	35	157	94.12
本文模型	48	9	97.39

为进一步验证在模型参数量降低后对检测精度的影响,针对卷积通道系数 alpha 值为 1、0.75、0.5 时 3 种情况,并进行对比实验。实验数据如表 7 所示。由表 7 可知,alpha 值在 1、0.75、0.5 时,模型大小显著变化,由 alpha 为 1 时的 149 MB 减少到 alpha 为 0.5 时的 9 MB。对比 alpha 为 1 与 alpha 为 0.5 时的模型平均分类精度可知,随着模型参数量大幅度减少,模型检测精度会受到一定影响,但该影响并不大,由表 7 中数据可知,alpha 值从 1 减少为 0.5,其平均分类精度分别减少了

0.45%、0.05%,即模型在尽可能少牺牲检测精度的前提下大幅度提升检测速度。

表 7 卷积通道系数 alpha 对比实验数据

alpha 值	模型大小/MB	模型平均分类精度/%
1	149	97.89
0.75	76	97.44
0.5	9	97.39

为验证 FPN-tiny 对模型精度的提升,针对 alpha 为 0.5 时添加与未添加 FPN-tiny 模块进行对比实验。实验数据如表 8 所示。由表 8 中数据可知,在添加 FPN-tiny 模块后模型检测精度提升较多,且一定程度上可加快检测速度。验证了 FPN-tiny 具有提升模型识别精度的作用。

表 8 FPN-tiny 模块对比实验

FPN-tiny	模型平均分类精度/%	单帧检测速度/ms
添加	97.39	20.83
未添加	89.45	18.29

3 模型部署

本文疲劳检测流程如图 12 所示,首先将实时采集到的驾驶员人脸图像输入至基于 Haar 特征的人脸检测分类器模块中^[18]定位检测目标,然后将定位后的检测数据送至 EMLite-Yolo-V4 眼嘴特征检测模型进行疲劳特征提取与检测,最后将提取到的特征送入疲劳特征参数计算模块进行计算并输出最终的判定结果。

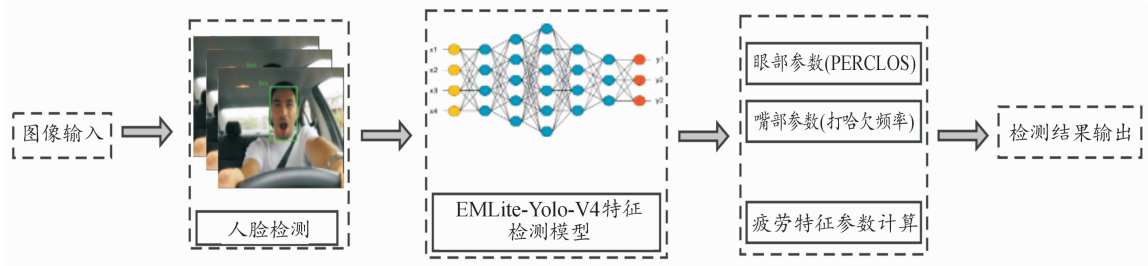


图 12 疲劳驾驶检测流程图

其中疲劳特征参数计算模块功能是将驾驶员睁眼、闭眼、张嘴、闭嘴 4 种特征的检测结果记录并根据 PERCLOS 和单位分钟打哈欠阈值数计算出疲劳程度,依据疲劳程度分数得出最终的疲劳驾驶检测结果。其中疲劳程度分为 3 个等级,分别为正常驾驶状态(NDS)、轻微疲劳驾驶(LFDS)、严重疲劳驾驶(EFDS)。分类依据如表 9 所示。

表 9 疲劳程度分类依据

疲劳程度	PERCLOS	单位分钟打哈欠数/次
正常驾驶	<0.25	0
轻微疲劳驾驶	>0.25	5
严重疲劳驾驶	>0.25	10

为验证本文模型对 3 种疲劳驾驶状态的检测效果,随机抽取了 3 名实验人员进行检测实验。实验模拟真实驾驶环境,由实验人员正前方摄像头实时采集面部信息,并且实验人员按照要求分别模拟出 3 种疲劳驾驶状态。每位实验人员分别进行 100 次模拟实验,共进行 300 次模拟实验。实验数据如表 10 所示。由表 10 可知,3 种疲劳驾驶状态的误检率较低,且平均分类准确率达到 98.28%,证明 3 种疲劳驾驶状态分类精度较高;其漏检率较低,证明本模型实际检测更具稳定性与鲁棒性;模型检测速度较快,实时 FPS 可达到 46 帧/s,检测实时性较高。实验过程中实时监测情况如图 13 所示。

表 10 疲劳程度实验数据

实验人员	疲劳程度	误检率/%	漏检率/%	分类准确率/%	实时平均 FPS/(帧 · s ⁻¹)
实验人员 A	正常驾驶	0.74	0.56	99.26	46.88
	轻微疲劳驾驶	2.41	1.98	97.59	
	严重疲劳驾驶	1.64	1.32	98.36	
实验人员 B	正常驾驶	0.53	0.33	99.47	46.43
	轻微疲劳驾驶	2.74	1.06	97.26	
	严重疲劳驾驶	2.17	1.65	97.83	
实验人员 C	正常驾驶	0.32	0.74	99.68	47.48
	轻微疲劳驾驶	2.31	1.37	97.69	
	严重疲劳驾驶	2.65	1.98	97.35	



图 13 疲劳程度实验实时监测图

4 结论

针对疲劳驾驶检测的准确性与实时性不平衡的问题,提出一种基于轻量化卷积神经网络 EM-Lite-Yolo-V4 的疲劳驾驶检测方法。通过使用轻量化卷积神经网络 MobileNet-V2 替换了 Yolo-V4 原有的主干提取网络,联合卷积通道参数 alpha 的缩小,使得整个 EMLite-Yolo-V4 网络的层数更少,检测速度更快。加入 FPN-tiny 轻量级特征金字塔模块过滤图像中的冗余信息,减少了 EMLite-Yolo-V4 在检测速度提升时带来的精度损失。同时,针对本文检测目标体积改进了 Yolo-V4 原有的 Soft-NMS,在检测过程中无需再同时考虑目标框的得分与重合度,使得本文方法检测速度进一步提升。最后通过对比实验证实了本文网络模型的有效

性,整体检测精度达到 97.39%,mAP 值达到 80.02%,较当前主流目标检测网络模型具有更高的精度。本方法在光线条件较好时具有较为稳定的检测效果,在后续工作中会加入红外图像,检测光线条件较差时的疲劳状态。

参考文献:

[1] 梁元辉,吴清乐,曹立佳.基于多特征融合的眼睛状态检测算法研究[J].计算机技术与发展,2021,31(2):97-100.

[2] 王艳玲.基于神经网络的疲劳驾驶识别系统[J].汽车实用技术,2021,46(1):89-91.

[3] 王欣,吴键,孙涵,等.基于 DSP 的疲劳驾驶视觉检测与预警系统设计[J].测试技术学报,2020,34(6):506-513.

[4] CHEN Long, ZHI Xiaojie, WANG Hai, et al. Driver fatigue detection via differential evolution extreme learning machine technique[J]. Electronics, 2020, 9(11):1850.

[5] WANG Zhong, SHI Peibei, WU Chao. A fatigue driving detection method based on deep learning and image processing[J]. Journal of Physics:Conference Series, 2020, 1575(1):012035.

[6] 朱名流,李顶根.基于人脸特征点的疲劳检测方法研究[J].计算机应用研究,2020,37(S2):305-307.

[7] 徐莲,任小洪,陈闰雪.基于眼睛状态识别的疲劳驾驶检测[J].科学技术与工程,2020,20(20):8292-8299.

[8] 王旭彬,韩毅,郭晓波.基于深度学习的多维疲劳驾驶检测系统[J].河南科技,2020,39(34):17-20.

[9] DENG Huafu, CHENG Jianghua, LIU Tong, et al. Re-

search on iron surface crack detection algorithm based on improved YOLOv4 network[J]. Journal of physics. Conference series,2020,1631(1):012081.

[10] LIU Bingyan,PAN Daru,SONG Hui. Joint optic disc and cup segmentation based on densely connected depthwise separable convolution deep network [J]. BMC Medical Imaging,2021,21(1):14.

[11] 孟球,徐磊,郭嘉阳. 一种基于改进的 MobileNetV2 网络语义分割算法[J]. 电子学报,2020,48(9):1769-1776.

[12] HUANG Juan,LIN Zihui. Multi-feature fatigue driving detection based on computer vision[J]. Journal of Physics: Conference Series,2020,1651(1):012188.

[13] ABTAHI S,OMIDYEGANEH M,SHIRMOHAMMADI S,et al. YawDD: A yawning detection dataset[C]//Proceedings of the 5th ACM Multimedia Systems Conference. New York:ACM,2014;24-28.

[14] GAO Zhongke,LI Yanli,YANG Yuxuan,et al. A recurrence network-based convolutional neural network for fatigue driving detection from EEG[J]. Chaos(Woodbury,N. Y.),2019,29(11):113126.

[15] 解尧婷,张丕状. 基于改进的 YOLOv4 输电线路小目标检测[J]. 国外电子测量技术,2021,40(2):47-51.

[16] 万卓,叶明,刘凯. 基于改进 YOLOv4 的电机端盖缺陷检测[J]. 计算机系统应用,2021,30(3):79-87.

[17] 谈小峰,王直杰. 基于 YOLOv4 改进算法的乒乓球识别[J]. 科技创新与应用,2020(27):74-76.

[18] 程耀瑜,丰婧,李树军,等. 一种基于 Haar 和肤色分割算法的人脸检测[J]. 兵器装备工程学报,2021,42(1):254-258.

Fatigue driving detection method based on lightweight convolutional neural network

CHENG Ze^{1,2,3}, LIN Fusheng^{1,2,3}, JIN Zhao^{1,2,3}, ZHOU Dinghe^{1,2,3}

(1. School of Mechanical Engineering and Automation,
Wuhan Textile University, Wuhan 430200, China;

2. Hubei Key Laboratory of Digital Textile Equipment, Wuhan 430200, China;

3. Three Dimensional Textile Engineering Research Center of Hubei, Wuhan 430200, China)

Abstract: Aiming at the imbalance between the accuracy and real-time performance of existing fatigue driving detection models, a detection model based on lightweight convolutional neural network EMLite-Yolo-V4 is designed. By using MobileNet-V2 as the main feature extraction network of Yolo-V4, and reducing the convolution channel coefficient alpha, the network parameters are greatly reduced; The flexible non maximum suppression is improved so that the target frame don't need to consider the score and coincidence degree at the same time, and the detection rate is further optimized; In order to ensure the detection accuracy of the model, the lightweight feature pyramid FPN tiny is added and the mosaic data enhancement method is fused. Finally, EMLite-Yolo-V4 is used to extract facial fatigue features. PERCLOS and yawning times per unit time are used to judge the fatigue features and output the results. The experimental results show that the accuracy of the detection model reaches 97.39%, the map index is 80.02%, the single frame detection speed is 20.83 ms, and the model size is only 9 MB, which effectively balances the accuracy and real-time of fatigue driving detection.

Key words: fatigue driving detection; lightweight convolutional neural network; lightweight feature pyramid; soft non maximum suppression; data enhancement